

TRƯỜNG ĐẠI HỌC KINH TẾ - ĐẠI HỌC ĐÀ NẴNG
KHOA THƯƠNG MẠI ĐIỆN TỬ



BÁO CÁO TIẾN ĐỘ 2

Đề tài:
**XÂY DỰNG PIPELINE DỮ LIỆU TỰ ĐỘNG CHO GỢI
Ý DU LỊCH VÀ TỐI ƯU TRẢI NGHIỆM KHÁCH
HÀNG TẠI ĐÀ NẴNG
TRÊN HỆ SINH THÁI GOOGLE CLOUD**

Học phần:
ĐỀ ÁN THỰC HÀNH 2

Giảng viên	:	TS. Lê Diên Tuấn
Lớp học phần	:	ELC3011
Nhóm	:	4
Họ và tên	:	Nguyễn Công Hiếu 49K29.1 Nguyễn Hoàng Duy 49K29.2 Trần Thị Ngọc Hà 49K29.2

Đà Nẵng, tháng 06 năm 2026

LỜI MỞ ĐẦU

Trong bối cảnh chuyển đổi số diễn ra mạnh mẽ trên toàn cầu, dữ liệu ngày càng được xem là một trong những tài sản quan trọng nhất của tổ chức và doanh nghiệp. Sự phát triển của các nền tảng trực tuyến, hệ thống giao dịch điện tử và các dịch vụ số đã tạo ra lượng dữ liệu khổng lồ với tốc độ gia tăng liên tục. Tuy nhiên, giá trị của dữ liệu chỉ có thể được khai thác hiệu quả khi dữ liệu được thu thập, xử lý, lưu trữ và cung cấp một cách có hệ thống. Điều này đã làm cho Data Engineering trở thành một lĩnh vực đóng vai trò nền tảng trong hệ sinh thái dữ liệu hiện đại.

Trong ngành du lịch, đặc biệt tại thành phố Đà Nẵng – một trong những trung tâm du lịch hàng đầu của Việt Nam – nhu cầu tìm kiếm và lựa chọn khách sạn phù hợp của du khách ngày càng tăng. Thông tin về khách sạn được phân tán trên nhiều nền tảng khác nhau như Booking.com, Agoda, ... với khối lượng lớn và liên tục thay đổi. Việc tổng hợp, chuẩn hóa và khai thác hiệu quả các nguồn dữ liệu này là một thách thức đáng kể nhưng đồng thời cũng mở ra cơ hội ứng dụng các kỹ thuật Data Engineering để xây dựng những hệ thống hỗ trợ ra quyết định thông minh hơn.

Xuất phát từ thực tiễn đó, nhóm lựa chọn thực hiện đề tài: “Xây dựng pipeline dữ liệu tự động cho gợi ý du lịch và tối ưu trải nghiệm khách hàng tại Đà Nẵng trên hệ sinh thái Google Cloud”. Đề tài tập trung vào việc thiết kế và triển khai một kiến trúc dữ liệu hoàn chỉnh theo định hướng Data Engineering, bao gồm các giai đoạn thu thập dữ liệu, xử lý và biến đổi dữ liệu, xây dựng kho dữ liệu, trực quan hóa dữ liệu và hỗ trợ gợi ý khách sạn cho người dùng. Thông qua việc ứng dụng các dịch vụ của Google Cloud Platform đề tài hướng đến việc xây dựng một hệ thống dữ liệu có khả năng tự động hóa, mở rộng linh hoạt và đáp ứng nhu cầu phân tích trong thực tế.

Bên cạnh việc vận dụng các kiến thức đã học về cơ sở dữ liệu, kho dữ liệu, quy trình ETL/ELT và điện toán đám mây, đề tài còn là cơ hội để nhóm tiếp cận quy trình triển khai một dự án dữ liệu theo hướng thực tiễn, từ giai đoạn thiết kế kiến trúc đến xây dựng sản phẩm hoàn chỉnh. Kết quả của đề tài không chỉ góp phần nâng cao trải nghiệm tìm kiếm nơi lưu trú của du khách mà còn minh họa khả năng ứng dụng của Data Engineering trong việc giải quyết các bài toán thực tế của ngành du lịch.

Nhóm xin gửi lời cảm ơn chân thành đến TS. Lê Diên Tuấn – giảng viên hướng dẫn đã tận tình định hướng, hỗ trợ và đóng góp nhiều ý kiến quý báu trong suốt quá trình thực hiện đề án. Mặc dù đã cố gắng hoàn thiện đề tài trong phạm vi kiến thức và thời gian cho phép, báo cáo khó tránh khỏi những thiếu sót nhất định. Nhóm rất mong nhận được những ý kiến đóng góp từ thầy để tiếp tục hoàn thiện và nâng cao chất lượng nghiên cứu trong tương lai.

MỤC LỤC

LỜI MỞ ĐẦU	3
I. TỔNG QUAN VỀ ĐỀ TÀI	8
1. Tên đề tài.....	8
2. Lý do chọn đề tài.....	8
3. Phạm vi nghiên cứu.....	8
4. Mục tiêu của đề tài	9
II. CƠ SỞ LÝ THUYẾT	10
1. Data Engineering.....	10
2. Data Pipeline	10
2.1. Khái niệm	10
2.2. Vai trò.....	11
2.3. Phân loại.....	11
3. Cào dữ liệu website	12
3.1. Giới thiệu.....	12
3.2. Quy trình cơ bản.....	12
3.3. Các phương pháp	13
3.4. Công cụ sử dụng.....	13
4. Quy trình xử lý dữ liệu.....	14
4.1. Giới thiệu về quy trình xử lý dữ liệu.....	14
4.2. Khái niệm ETL.....	14
5. Hệ thống lưu trữ dữ liệu.....	14
6. Các mô hình lược đồ trong kho dữ liệu	15
6.1. Khái niệm chung về lược đồ kho dữ liệu	15
6.2. Star Schema.....	16
7. Google Cloud Platform	17
7.1. Tổng quan về Google Cloud Platform	17

7.2. Các dịch vụ của Google Cloud Platform	17
7.2.1. Phát triển và sử dụng Trí tuệ nhân tạo	17
7.2.2. Tạo và vận hành trên cơ sở hạ tầng Google Cloud.....	18
7.2.3. Truy cập dữ liệu phân tích và tạo cơ sở dữ liệu.....	18
7.2.4. Tìm kiếm các công cụ phát triển phổ biến.....	19
7.2.5. Phát triển các ứng dụng và tính năng.....	19
III. KẾT QUẢ THỰC HIỆN.....	21
1. Framework	21
1.1. Tổng quan kiến trúc pipeline	21
1.2. Luồng dữ liệu trong Pipeline	22
1.2.1. Data Source – Nguồn Dữ liệu	22
1.2.2. Ingestion – Thu thập và Phân tích Dữ liệu	22
1.2.3. Storage – Lưu trữ Dữ liệu Thô.....	22
1.2.4. Processing – Xử lý và Biến đổi Dữ liệu.....	22
1.2.5. Data Warehouse – Kho Dữ liệu Tập trung	23
1.2.6. Consumption – Khai thác và Trình bày Dữ liệu	23
2. Mô tả dữ liệu	24
2.1. Nguồn gốc dữ liệu.....	24
2.2. Phạm vi dữ liệu	24
2.3. Các thành phần dữ liệu thu thập.....	24
3. Kết quả thực hiện	32
3.1. Cào dữ liệu	32
3.1.1. Giai đoạn 1: Giả lập và Tương tác động bằng Selenium.....	32
3.1.2. Giai đoạn 2: Trích xuất cấu trúc HTML qua File Crawl API...	33
3.1.3. Giai đoạn 3: Đóng gói và lưu dữ liệu.....	35
3.2. Lưu trữ dữ liệu thô	35
3.3. ETL.....	38

3.3.1. Extract (Trích xuất dữ liệu).....	38
3.3.2. Transform	41
3.3.3. Load.....	45
3.4. Data Warehouse	48
IV. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	54
1. Kết luận	54
2. Hạn chế của đề tài	54
3. Hướng phát triển trong tương lai	55
TÀI LIỆU THAM KHẢO	56

I. TỔNG QUAN VỀ ĐỀ TÀI

1. Tên đề tài

“Xây dựng pipeline dữ liệu tự động cho gợi ý du lịch và tối ưu trải nghiệm khách hàng tại Đà Nẵng trên hệ sinh thái Google Cloud”

Câu hỏi phân tích: “Làm thế nào để xác định và đề xuất các khách sạn phù hợp, giúp du khách tối ưu trải nghiệm lưu trú tại khu vực Đà Nẵng?”

2. Lý do chọn đề tài

Sự phát triển mạnh mẽ của công nghệ số và xu hướng chuyển đổi số trong ngành du lịch đã tạo ra lượng dữ liệu khổng lồ từ nhiều nguồn khác nhau như thông tin khách sạn, đánh giá của khách hàng, vị trí địa lý, giá phòng và các tiện ích đi kèm. Tuy nhiên, các dữ liệu này thường phân tán, được cập nhật liên tục và tồn tại dưới nhiều định dạng khác nhau, gây khó khăn cho việc khai thác và đưa ra các gợi ý phù hợp cho du khách. Đặc biệt tại thành phố Đà Nẵng – một trong những trung tâm du lịch lớn của Việt Nam – số lượng khách sạn và cơ sở lưu trú ngày càng gia tăng, khiến việc lựa chọn nơi lưu trú phù hợp với nhu cầu trở nên không hề đơn giản.

Đối với du khách, việc tìm kiếm khách sạn không chỉ dựa trên giá phòng mà còn phụ thuộc vào nhiều yếu tố như vị trí, khoảng cách đến các điểm tham quan, chất lượng dịch vụ, mức độ đánh giá và các tiện ích đi kèm. Nếu phải tìm kiếm thông tin từ nhiều nền tảng khác nhau, người dùng sẽ mất nhiều thời gian, đồng thời khó có thể đưa ra quyết định tối ưu. Về phía doanh nghiệp du lịch và các đơn vị quản lý khách sạn, việc chưa khai thác hiệu quả nguồn dữ liệu sẵn có cũng làm giảm khả năng tiếp cận đúng nhóm khách hàng, ảnh hưởng đến hiệu quả kinh doanh và trải nghiệm của khách lưu trú.

3. Phạm vi nghiên cứu

Đề tài được thực hiện trong phạm vi thành phố Đà Nẵng, tập trung nghiên cứu các khách sạn và cơ sở lưu trú được đăng tải trên nền tảng Booking.com. Dữ liệu sử dụng trong nghiên cứu được thu thập bằng kỹ thuật web scraping, bao gồm các thông tin như tên khách sạn, địa chỉ, mức giá, hạng sao, điểm đánh giá, số lượng đánh giá, mô tả, tiện ích và các thông tin liên quan phục vụ cho việc xây dựng kho dữ liệu và phân tích.

Về mặt công nghệ, đề tài giới hạn trong việc nghiên cứu quy trình ETL (Extract – Transform – Load), mô hình kho dữ liệu (Data Warehouse), hệ quản trị cơ sở dữ liệu và các công cụ trực quan hóa dữ liệu trên nền tảng Google Cloud. Đề tài khai thác dữ liệu từ các nền tảng đặt phòng như [Booking.com](https://www.booking.com), Agoda và nền tảng đánh giá trải nghiệm khách hàng như Google Map để phục vụ cho quá trình phân tích.

4. Mục tiêu của đề tài

Mục tiêu của đề tài là xây dựng một hệ thống hỗ trợ phân tích và gợi ý khách sạn tại thành phố Đà Nẵng dựa trên nền tảng Data Warehouse, góp phần nâng cao hiệu quả khai thác dữ liệu và cải thiện trải nghiệm tìm kiếm nơi lưu trú của người dùng. Đề tài hướng đến việc hình thành một nguồn dữ liệu tập trung, có tính nhất quán và độ tin cậy cao, làm cơ sở cho việc phân tích, trực quan hóa và hỗ trợ ra quyết định.

Bên cạnh đó, đề tài hướng tới việc xây dựng một hệ thống tự động thu thập, xử lý và lưu trữ dữ liệu, giảm thiểu sự can thiệp thủ công và nâng cao hiệu quả quản lý dữ liệu. Trên cơ sở dữ liệu đã được tổ chức trong kho dữ liệu, đề tài xây dựng các Dashboard trực quan giúp người dùng và nhà quản lý dễ dàng theo dõi, phân tích các thông tin quan trọng như mức giá, hạng sao, điểm đánh giá và các tiện ích của khách sạn.

Ngoài ra, đề tài còn hướng đến việc phát triển một hệ thống web gợi ý khách sạn, cho phép người dùng tìm kiếm và lựa chọn nơi lưu trú phù hợp dựa trên các tiêu chí như vị trí, mức giá, hạng sao, điểm đánh giá và tiện ích. Qua đó, hệ thống không chỉ hỗ trợ người dùng đưa ra quyết định nhanh chóng và chính xác hơn mà còn thể hiện khả năng ứng dụng của Data Warehouse trong việc giải quyết các bài toán thực tế trong lĩnh vực du lịch và lưu trú.

II. CƠ SỞ LÝ THUYẾT

1. Data Engineering

Data Engineering là lĩnh vực tập trung vào việc thiết kế, xây dựng và vận hành hạ tầng dữ liệu nhằm bảo đảm dữ liệu được thu thập, xử lý và cung cấp một cách ổn định, nhất quán và có khả năng mở rộng. Nếu khoa học dữ liệu quan tâm nhiều đến việc khai thác mô hình từ dữ liệu thì kỹ thuật dữ liệu lại chú trọng đến việc tạo ra dòng chảy dữ liệu đáng tin cậy để các hoạt động phân tích đó có thể diễn ra. Nói cách khác, Data Engineering là lớp nền hạ tầng giúp dữ liệu từ trạng thái thô và phân tán trở thành tài nguyên có thể sử dụng hiệu quả cho báo cáo, trực quan hóa và phân tích chuyên sâu.

Trong thực tiễn, vai trò của Data Engineering đặc biệt quan trọng khi tổ chức phải xử lý khối lượng dữ liệu lớn, dữ liệu đến từ nhiều nguồn và có nhu cầu cập nhật thường xuyên. Một hệ thống dữ liệu nếu thiếu thiết kế kỹ thuật phù hợp sẽ dễ gặp các vấn đề như dữ liệu không nhất quán, quy trình xử lý thủ công, khó kiểm soát chất lượng và khó mở rộng khi số lượng dữ liệu tăng lên. Vì vậy, tiếp cận theo hướng Data Engineering không chỉ giải quyết vấn đề kỹ thuật mà còn nâng cao khả năng sử dụng dữ liệu như một tài sản chiến lược của tổ chức.

Trong phạm vi đề án, Data Engineering được xem là định hướng trung tâm, trong đó trọng tâm không nằm ở việc xây dựng mô hình học máy mà ở việc hình thành một kiến trúc dữ liệu hoàn chỉnh từ khâu thu thập dữ liệu nguồn, xử lý và biến đổi dữ liệu, tổ chức lưu trữ trong kho dữ liệu cho đến phục vụ truy vấn, trực quan hóa và phân tích nghiệp vụ.

2. Data Pipeline

2.1. Khái niệm

Data Pipeline là hệ thống hoặc chuỗi quy trình tự động cho phép dữ liệu di chuyển từ nguồn phát sinh đến nơi lưu trữ và tiêu thụ cuối cùng. Một pipeline dữ liệu thường bao gồm các bước chính: thu thập dữ liệu từ nguồn, đưa dữ liệu vào hệ thống xử lý, thực hiện làm sạch và biến đổi, sau đó nạp dữ liệu vào hệ thống đích như kho dữ liệu hoặc nền tảng phân tích. Nhờ có pipeline, việc xử lý dữ liệu không còn phụ thuộc vào thao tác thủ công mà được tổ chức thành một luồng vận hành có thể lặp lại, giám sát và mở rộng.

Về mặt bản chất, data pipeline đóng vai trò là xương sống của toàn bộ kiến trúc dữ liệu. Nó bảo đảm rằng dữ liệu từ nhiều nguồn khác nhau được chuẩn hóa theo cùng một logic xử lý trước khi đưa vào khai thác. Một pipeline được thiết kế tốt sẽ giúp giảm thiểu sai sót, rút ngắn thời gian cập nhật dữ liệu và tăng độ tin cậy cho các báo cáo đầu ra. Trong khi đó, nếu không có pipeline rõ ràng, dữ liệu rất dễ bị phân mảnh, khó đối soát và không đảm bảo tính nhất quán giữa các lần xử lý.

2.2. Vai trò

Sự phát triển mạnh mẽ của các hệ thống số, thương mại điện tử, ứng dụng di động, mạng xã hội, thiết bị IoT, ... đã làm cho khối lượng dữ liệu tăng nhanh cả về quy mô lẫn tốc độ phát sinh. Trong giai đoạn đầu, doanh nghiệp có thể quản lý dữ liệu bằng bảng tính hoặc cơ sở dữ liệu đơn giản. Tuy nhiên, khi dữ liệu trở nên lớn hơn, đa dạng hơn và yêu cầu cập nhật nhanh hơn, các phương pháp thủ công dần bộc lộ nhiều hạn chế như chậm trễ, thiếu nhất quán và khó mở rộng. Chính trong bối cảnh đó, Data Pipeline trở thành một thành phần thiết yếu của hệ thống dữ liệu hiện đại.

Về bản chất, Data Pipeline giúp tự động hóa toàn bộ vòng đời xử lý dữ liệu từ nguồn đến nơi khai thác. Điều này mang lại nhiều lợi ích quan trọng. Thứ nhất, pipeline hỗ trợ xử lý khối lượng dữ liệu lớn một cách hiệu quả hơn so với thao tác thủ công. Thứ hai, pipeline cho phép rút ngắn thời gian cập nhật dữ liệu, từ đó hỗ trợ ra quyết định nhanh hơn. Thứ ba, quá trình tự động hóa giúp giảm lỗi do con người, bảo đảm tính nhất quán giữa các lần xử lý. Thứ tư, pipeline đóng vai trò tích hợp dữ liệu từ nhiều nguồn khác nhau, phá vỡ tình trạng dữ liệu phân mảnh và cô lập. Cuối cùng, pipeline tạo nền tảng để triển khai các hệ thống báo cáo, phân tích và trí tuệ nhân tạo trên cùng một nguồn dữ liệu đã được chuẩn hóa.

2.3. Phân loại

Dựa trên phương thức xử lý, Data Pipeline thường được chia thành bốn nhóm chính: batch pipeline, streaming pipeline, data integration pipeline và cloud-native pipeline.

Batch processing pipeline là mô hình xử lý dữ liệu theo lô tại các thời điểm xác định trước. Đây là hình thức phù hợp với các hệ thống báo cáo định kỳ, tổng hợp doanh thu hoặc phân tích dữ liệu lịch sử. Ưu điểm của batch pipeline là đơn giản

hơn trong thiết kế và quản lý, nhưng độ trễ thường cao hơn do dữ liệu không được cập nhật ngay lập tức.

Streaming data pipeline xử lý dữ liệu gần thời gian thực ngay khi dữ liệu phát sinh. Mô hình này phù hợp với các hệ thống cần phản ứng nhanh như phát hiện gian lận, theo dõi hành vi người dùng hoặc giám sát giao dịch trực tuyến. Tuy nhiên, do yêu cầu cao về độ trễ và khả năng chịu lỗi, streaming pipeline thường phức tạp hơn trong triển khai.

Data integration pipeline tập trung vào việc tổng hợp dữ liệu từ nhiều hệ thống nguồn khác nhau thành một tập dữ liệu thống nhất. Đây là loại pipeline phổ biến trong các doanh nghiệp có nhiều phần mềm nghiệp vụ độc lập và cần một lớp dữ liệu hợp nhất cho phân tích tổng thể.

Cloud-native pipeline là pipeline được xây dựng trực tiếp trên nền tảng đám mây, tận dụng các dịch vụ quản lý sẵn để tăng tính mở rộng, linh hoạt và tối ưu chi phí vận hành. Mô hình này đặc biệt phù hợp với các hệ thống dữ liệu hiện đại, trong đó hạ tầng xử lý và lưu trữ cần thích ứng nhanh với mức tải biến động.

3. Cào dữ liệu website

3.1. Giới thiệu

Cào dữ liệu web là quá trình sử dụng chương trình tự động để truy cập các trang web, thu thập nội dung và trích xuất những thông tin cần thiết dưới dạng dữ liệu có cấu trúc. Kỹ thuật này giúp chuyển đổi dữ liệu từ môi trường web, vốn thường ở dạng phi cấu trúc hoặc bán cấu trúc, thành dữ liệu có thể lưu trữ, phân tích và khai thác trong các hệ thống thông tin.

Cào dữ liệu hiện được ứng dụng rộng rãi trong nhiều lĩnh vực như thương mại điện tử, du lịch, tài chính, truyền thông và nghiên cứu dữ liệu, đặc biệt trong các bài toán cần thu thập thông tin từ nhiều nguồn trực tuyến một cách tự động.

3.2. Quy trình cơ bản

Quy trình cào dữ liệu web thường gồm các bước cơ bản sau:

Xác định nguồn dữ liệu và mục tiêu thu thập: lựa chọn website, loại dữ liệu cần lấy và phạm vi thu thập.

Truy cập và tải nội dung trang web: gửi yêu cầu đến website hoặc sử dụng trình duyệt tự động để hiển thị nội dung.

Phân tích cấu trúc trang: xác định vị trí dữ liệu trong HTML hoặc DOM.

Trích xuất dữ liệu: lấy các trường thông tin cần thiết như tên, giá, địa chỉ, đánh giá hoặc mô tả.

Làm sạch và lưu trữ: chuẩn hóa dữ liệu và lưu vào các định dạng như CSV, JSON hoặc cơ sở dữ liệu.

3.3. Các phương pháp

Một số phương pháp cào dữ liệu phổ biến gồm:

Cào dữ liệu bằng HTTP request: phù hợp với các trang tĩnh, nơi dữ liệu có thể lấy trực tiếp từ mã nguồn HTML.

Phân tích DOM/HTML: sử dụng các bộ phân tích để tìm và trích xuất dữ liệu từ các thẻ HTML cụ thể.

Sử dụng trình duyệt tự động: áp dụng cho các website có nội dung tải động bằng JavaScript, thông qua các công cụ như Selenium hoặc Playwright.

Khai thác API: nếu website cung cấp API, đây là phương pháp hiệu quả và ổn định hơn so với phân tích HTML.

Trong thực tế, các hệ thống thường kết hợp nhiều phương pháp để tăng hiệu quả và độ chính xác khi thu thập dữ liệu.

3.4. Công cụ sử dụng

Selenium: Là một khung thử nghiệm tự động hóa trình duyệt (Browser Automation Framework) mạnh mẽ. Trong bài toán cào dữ liệu, Selenium đóng vai trò giả lập các hành vi của người dùng thực tế như cuộn trang (scroll), nhấp chuột (click), chọn ngày check-in/check-out và đợi các thành phần giao diện tải hoàn chỉnh. Công cụ này là giải pháp tối ưu đối với các website sử dụng cơ chế kết xuất phía máy khách (Client-side rendering) và tải nội dung động bằng JavaScript phức tạp, giúp hệ thống tiếp cận được các lớp dữ liệu ẩn phía sau các bộ lọc.

Firecrawl: Là một công cụ chuyên dụng tiên tiến được tối ưu hóa cho việc chuyển đổi toàn bộ nội dung của một trang web thành dữ liệu có cấu trúc sạch

dưới định dạng Markdown hoặc JSON. Firecrawl sở hữu khả năng tự động xử lý các trang web có kiến trúc lồng nhau, tự động thu thập các liên kết phụ (sub-links) và loại bỏ các thành phần nhiễu thông tin (như quảng cáo, mã đi kèm). Dữ liệu đầu ra sạch của Firecrawl giúp tối giản hóa giai đoạn tiền xử lý và tăng tốc độ làm sạch dữ liệu trước khi nạp vào kho lưu trữ.

4. Quy trình xử lý dữ liệu

4.1. Giới thiệu về quy trình xử lý dữ liệu

Trong các hệ thống dữ liệu hiện đại, dữ liệu thường được thu thập từ nhiều nguồn khác nhau như cơ sở dữ liệu giao dịch, tệp dữ liệu, API hoặc log hệ thống. Do sự khác biệt về cấu trúc, định dạng và chất lượng, dữ liệu nguồn thường chưa thể đưa vào phân tích trực tiếp. Vì vậy, cần một quy trình kỹ thuật để tích hợp, làm sạch và chuẩn hóa dữ liệu trước khi lưu trữ trong hệ thống phân tích. Hai cách tiếp cận phổ biến nhất cho mục đích này là ETL và ELT.

4.2. Khái niệm ETL

ETL (Extract – Transform – Load) là quy trình gồm ba bước: trích xuất dữ liệu từ nguồn, biến đổi dữ liệu theo yêu cầu nghiệp vụ, sau đó nạp dữ liệu đã xử lý vào hệ thống đích. Trong mô hình này, công đoạn biến đổi diễn ra trước khi dữ liệu được đưa vào kho lưu trữ phân tích. ETL thường được sử dụng trong các hệ thống truyền thống, nơi yêu cầu dữ liệu phải được kiểm tra và chuẩn hóa chặt chẽ trước khi nạp vào kho dữ liệu.

Ở bước Extract, dữ liệu được lấy từ nhiều nguồn như cơ sở dữ liệu vận hành, API hoặc tệp dữ liệu. Ở bước Transform, dữ liệu được làm sạch, loại bỏ trùng lặp, xử lý giá trị thiếu, chuẩn hóa kiểu dữ liệu, tích hợp giữa các nguồn và tính toán các chỉ số phục vụ nghiệp vụ. Cuối cùng, ở bước Load, dữ liệu đã chuẩn hóa được nạp vào kho dữ liệu hoặc data mart để phục vụ phân tích.

5. Hệ thống lưu trữ dữ liệu

Trong kiến trúc dữ liệu hiện đại, việc lựa chọn hệ thống lưu trữ không chỉ ảnh hưởng đến chi phí mà còn quyết định khả năng mở rộng, hiệu năng truy vấn và mức độ linh hoạt trong khai thác dữ liệu. Ba hệ thống (mô hình) phổ biến hiện nay gồm Data Lake, Data Warehouse và Data Lakehouse. Mỗi mô hình có mục

tiêu thiết kế và phạm vi ứng dụng khác nhau, nhưng đều hướng đến việc phục vụ tốt hơn cho các nhu cầu quản trị, phân tích và khai thác dữ liệu của tổ chức.

Data Warehouse (Kho dữ liệu) là hệ thống lưu trữ và quản lý dữ liệu tập trung được thiết kế chuyên biệt cho mục đích phân tích và hỗ trợ ra quyết định. Khác với data lake, dữ liệu trong data warehouse thường đã được làm sạch, chuẩn hóa và tổ chức theo các mô hình phù hợp cho truy vấn phân tích như star schema hoặc snowflake schema. Kho dữ liệu được tối ưu cho các truy vấn tổng hợp, phân tích lịch sử và xây dựng dashboard.

Data warehouse đặc biệt phù hợp cho các bài toán BI, báo cáo quản trị và phân tích nghiệp vụ, nơi yêu cầu tính nhất quán, độ tin cậy cao và hiệu năng truy vấn tốt. Trong đề án của bạn, đây gần như là “ngôi nhà chính” của dữ liệu phân tích, không phải chỉ là kho chứa đồ tạm.

6. Các mô hình lược đồ trong kho dữ liệu

6.1. Khái niệm chung về lược đồ kho dữ liệu

Trong hệ thống kho dữ liệu, bên cạnh việc lựa chọn nền tảng lưu trữ, việc tổ chức dữ liệu theo mô hình lược đồ phù hợp có vai trò rất quan trọng đối với hiệu năng truy vấn, khả năng mở rộng và mức độ thuận tiện khi phân tích.

Lược đồ kho dữ liệu là cấu trúc tổ chức các bảng dữ liệu nhằm phục vụ truy vấn phân tích. Khác với mô hình dữ liệu trong cơ sở dữ liệu giao dịch, nơi mục tiêu chính là bảo đảm tính toàn vẹn và tối ưu cho các thao tác cập nhật, lược đồ trong kho dữ liệu được thiết kế theo hướng hỗ trợ tổng hợp, phân tích lịch sử và truy vấn đa chiều. Trong các lược đồ này, dữ liệu thường được chia thành hai nhóm bảng chính là bảng sự kiện (fact table) và bảng chiều (dimension table).

Bảng sự kiện lưu trữ các số đo hoặc chỉ số nghiệp vụ có thể định lượng, chẳng hạn như doanh thu, số lượng giao dịch, số tiền thanh toán hoặc số lượt truy cập. Đây là bảng trung tâm trong phân tích vì chứa các giá trị cần tổng hợp, đếm, cộng hoặc so sánh theo thời gian. Trong khi đó, bảng chiều chứa thông tin mô tả và ngữ cảnh cho dữ liệu, chẳng hạn như thời gian, khách hàng, sản phẩm, khu vực hoặc trạng thái giao dịch. Các bảng chiều giúp người dùng phân tích dữ liệu theo nhiều góc nhìn khác nhau, từ đó hỗ trợ ra quyết định hiệu quả hơn.

Lược đồ dữ liệu trong kho dữ liệu không chỉ phản ánh cách dữ liệu được lưu trữ mà còn thể hiện cách dữ liệu được liên kết và khai thác theo nhiều chiều nghiệp vụ. Trong thực tế, các mô hình lược đồ phổ biến nhất gồm Star Schema, Snowflake Schema và Galaxy Schema. Mỗi mô hình có đặc điểm riêng, phù hợp với những yêu cầu tổ chức dữ liệu và mức độ phức tạp khác nhau.

6.2. Star Schema



Star Schema (Lược đồ hình sao) là mô hình lược đồ phổ biến nhất trong kho dữ liệu. Mô hình này gồm một bảng fact ở trung tâm và nhiều bảng dimension bao quanh, tạo thành hình dạng giống ngôi sao. Trong star schema, các bảng dimension thường được phi chuẩn hóa ở mức nhất định, nghĩa là các thuộc tính mô tả được giữ trong cùng một bảng thay vì tiếp tục tách nhỏ thành nhiều bảng con. Điều này giúp cấu trúc dữ liệu trở nên trực quan, dễ hiểu và dễ truy vấn hơn.

Ưu điểm lớn nhất của star schema là đơn giản trong thiết kế và hiệu quả trong truy vấn phân tích. Do số lượng phép nối giữa các bảng được giảm thiểu, các công cụ BI có thể khai thác dữ liệu nhanh hơn và người dùng cũng dễ hình dung mối quan hệ giữa dữ liệu sự kiện và các chiều phân tích. Star schema đặc biệt phù hợp với các hệ thống dashboard, báo cáo quản trị và các bài toán phân tích đa chiều.

Tuy nhiên, do các bảng dimension thường được phi chuẩn hóa, mô hình này có thể dẫn đến dư thừa dữ liệu ở mức nhất định. Dù vậy, trong môi trường data

warehouse, sự đánh đổi này thường được chấp nhận để đổi lấy hiệu năng truy vấn và sự đơn giản trong khai thác.

7. Google Cloud Platform

7.1. Tổng quan về Google Cloud Platform

Google Cloud Platform (GCP) là nền tảng điện toán đám mây cung cấp nhiều dịch vụ phục vụ xây dựng, vận hành và mở rộng hệ thống dữ liệu hiện đại. Trong bối cảnh dữ liệu ngày càng lớn và yêu cầu xử lý ngày càng linh hoạt, việc triển khai hệ thống trên nền tảng cloud giúp giảm gánh nặng quản trị hạ tầng, đồng thời tận dụng được khả năng mở rộng theo nhu cầu thực tế. Đối với các bài toán Data Engineering, GCP cung cấp hệ sinh thái tương đối đầy đủ cho các bước lưu trữ, xử lý, điều phối đến trực quan hóa dữ liệu.

7.2. Các dịch vụ của Google Cloud Platform

Dựa trên giao diện và danh mục sản phẩm hiện hành của Google, hệ sinh thái GCP có thể được phân thành các nhóm chính, hỗ trợ xuyên suốt vòng đời của một dự án dữ liệu.

Dưới đây là các dịch vụ nổi bật và thường xuyên của từng nhóm được ứng dụng nhất trong việc xây dựng kiến trúc dữ liệu và Data Pipeline trên GCP:

7.2.1. Phát triển và sử dụng Trí tuệ nhân tạo

Gemini Enterprise Agent Platform (Nền tảng AI và ML): Nền tảng hợp nhất giúp các tổ chức xây dựng, tinh chỉnh các mô hình học máy (ML), ứng dụng AI tạo sinh và tạo ra các tác nhân AI (AI agents) một cách dễ dàng.

Gemini Enterprise app (Nền tảng tác nhân): Ứng dụng cho phép bạn khám phá, tạo, chia sẻ và thực thi các tác nhân AI trong toàn bộ tổ chức của mình, được vận hành trong một môi trường bảo mật, an toàn.

Vertex AI: Nền tảng học máy (ML) toàn diện giúp xây dựng, huấn luyện và triển khai các mô hình AI (bao gồm cả Generative AI) ở quy mô lớn.

Vertex AI Studio (hoặc Generative AI Studio): Công cụ cho phép nhà phát triển nhanh chóng thử nghiệm, tinh chỉnh và triển khai các mô hình nền tảng AI tạo sinh.

7.2.2. Tạo và vận hành trên cơ sở hạ tầng Google Cloud

Cloud Storage: Là dịch vụ lưu trữ đối tượng (object storage) an toàn, bền bỉ và có khả năng mở rộng vô hạn. Trong quy trình xử lý dữ liệu, Cloud Storage thường được sử dụng làm Data Lake – nơi tập kết dữ liệu nguồn (raw data) đa định dạng (CSV, JSON, hình ảnh, log file) hoặc làm không gian lưu trữ trung gian trước khi nạp vào kho dữ liệu.

Compute Engine: Dịch vụ máy chủ ảo (Virtual Machines - VM). Đây là nền tảng cốt lõi cung cấp tài nguyên máy tính có thể tùy chỉnh CPU, RAM linh hoạt theo nhu cầu.

Google Kubernetes Engine (GKE): Dịch vụ quản lý vùng chứa (container) hàng đầu, giúp tự động hóa việc triển khai, mở rộng và quản lý các ứng dụng container hóa.

Cloud TPUs (Tensor Processing Unit): Hệ thống phần cứng (bộ xử lý) do chính Google thiết kế chuyên biệt để tăng tốc độ xử lý cho các khối lượng công việc liên quan đến Machine Learning và AI.

7.2.3. Truy cập dữ liệu phân tích và tạo cơ sở dữ liệu

BigQuery (Kho dữ liệu - Data Warehouse): Dịch vụ kho dữ liệu đám mây hoàn toàn tự động, không cần máy chủ (serverless). Giúp doanh nghiệp phân tích hàng petabyte dữ liệu nhanh chóng bằng SQL để đưa ra các quyết định kinh doanh (insights).

Looker (Nền tảng thông minh doanh nghiệp - Business Intelligence): Công cụ phân tích và trực quan hóa dữ liệu (dashboard, báo cáo), giúp các đội ngũ trong công ty dễ dàng tiếp cận và khai thác dữ liệu tích hợp.

Cloud SQL: Dịch vụ cơ sở dữ liệu quan hệ (Relational Database) được quản lý hoàn toàn cho MySQL, PostgreSQL và SQL Server, giúp giảm bớt công việc quản trị database.

Dataproc: Là dịch vụ được quản lý toàn diện để chạy các cụm Apache Spark, Presto và Apache Hadoop trên nền tảng đám mây. Dịch vụ này rất hữu ích cho các bài toán phân tích dữ liệu lớn phức tạp, hoặc khi tổ chức muốn dịch chuyển các hệ sinh thái Big Data truyền thống lên môi trường cloud một cách nhanh chóng và tối ưu chi phí.

Dataflow: Là dịch vụ xử lý dữ liệu được quản lý toàn diện, hỗ trợ đồng thời cả luồng dữ liệu thời gian thực (streaming) và xử lý theo lô (batch). Được xây dựng dựa trên Apache Beam, Dataflow là công cụ cốt lõi để triển khai các quy trình trích xuất, biến đổi và nạp (ETL/ELT), giúp làm sạch và chuẩn hóa dữ liệu tự động.

Pub/Sub: Là dịch vụ nhắn tin bất đồng bộ hoạt động theo mô hình publish-subscribe. Dịch vụ này đặc biệt quan trọng trong các kiến trúc hướng sự kiện (event-driven) hoặc luồng xử lý streaming, giúp tiếp nhận và phân phối luồng dữ liệu khổng lồ từ các nguồn phát sinh liên tục (như thiết bị IoT, log website) một cách ổn định với độ trễ cực thấp.

Cloud Spanner / AlloyDB: Các giải pháp cơ sở dữ liệu quan hệ cao cấp dành cho doanh nghiệp có quy mô cực lớn, đảm bảo tính khả dụng cao và khả năng mở rộng ngang (horizontal scaling) toàn cầu.

7.2.4. Tìm kiếm các công cụ phát triển phổ biến

Gemini Code Assist (Hỗ trợ lập trình bằng AI): Công cụ AI hỗ trợ các lập trình viên ngay trong môi trường code (IDE) bằng cách tự động hoàn thành code, tạo code từ văn bản, hoặc giải thích/gỡ lỗi code.

Cloud Shell (Terminal phát triển trực tuyến): Môi trường shell (dòng lệnh) tương tác có sẵn ngay trên trình duyệt, được tích hợp sẵn các công cụ cần thiết cho nhà phát triển mà không cần phải cài đặt phức tạp trên máy cá nhân.

Cloud Run: Nền tảng điện toán Serverless cho phép chạy các container ứng dụng một cách linh hoạt. Nền tảng này có khả năng tự động scale về 0 và bạn chỉ phải trả tiền khi ứng dụng thực sự xử lý request.

7.2.5. Phát triển các ứng dụng và tính năng

AppSheet (Nền tảng không cần lập trình - No-code platform): Giải pháp giúp bất kỳ ai cũng có thể tự tạo, mở rộng và phát triển các ứng dụng nội bộ hoặc ứng dụng quản lý quy trình làm việc mà không cần phải viết code.

Cloud Build: Dịch vụ tích hợp và phân phối liên tục (CI/CD) không cần máy chủ, giúp tự động hóa toàn bộ quy trình xây dựng, kiểm thử và triển khai mã nguồn lên các môi trường.

Cloud Run functions (trước đây là Cloud Functions): Dịch vụ Serverless hướng sự kiện (event-driven), chuyên dùng để chạy các đoạn code ngắn (hàm) nhằm phản hồi tự động lại các sự kiện cụ thể hoặc các lệnh gọi HTTP mà không cần phải quản lý máy chủ nền tảng.

Cloud Scheduler: Dịch vụ lập lịch công việc (cron job) hoàn toàn tự động trên GCP. Dịch vụ này giúp lên lịch và kích hoạt định kỳ các tác vụ (như gọi HTTP, chạy Cloud functions, gửi tin nhắn Pub/Sub). Trong Data Engineering, Cloud Scheduler đóng vai trò là trình kích hoạt (trigger) để tự động chạy các luồng xử lý dữ liệu (ETL/ELT, batch processing) theo khung giờ định sẵn mà không cần quản lý hạ tầng.

Artifact Registry: Trình quản lý gói (package manager) thống nhất của Google Cloud. Dịch vụ này dùng để quản lý, lưu trữ và bảo mật các container image (như Docker) và các gói ngôn ngữ lập trình của bạn một cách tập trung trước khi đem đi triển khai.

III. KẾT QUẢ THỰC HIỆN


1. Framework

1.1. Tổng quan kiến trúc pipeline

Hệ thống được xây dựng theo mô hình Time-Driven Data Pipeline trên nền tảng Google Cloud Platform (GCP). Kiến trúc này cho phép tự động hóa toàn bộ quy trình từ thu thập dữ liệu khách sạn trên Booking.com, Agoda và Google Maps Reviews, đến xử lý, lưu trữ tập trung, phân tích bằng trí tuệ nhân tạo và trực quan hóa kết quả cho người dùng cuối.

Mô hình được thiết kế theo định hướng Serverless nhằm giảm chi phí vận hành, tăng khả năng mở rộng và loại bỏ nhu cầu quản trị hạ tầng vật lý. Toàn bộ các thành phần chỉ được cấp phát tài nguyên khi phát sinh khối lượng công việc, giúp tối ưu chi phí sử dụng dịch vụ đám mây. Đặc trưng cốt lõi của mô hình là toàn bộ pipeline được kích hoạt tự động theo lịch định sẵn mỗi 24 giờ, đảm bảo dữ liệu được cập nhật định kỳ mà không cần bất kỳ sự can thiệp thủ công nào từ người vận hành.

Luồng dữ liệu chính của hệ thống bao gồm sáu giai đoạn chức năng: Data Source, Ingestion, Storage, Processing, Data Warehouse và Consumption.



1.2. Luồng dữ liệu trong Pipeline

1.2.1. Data Source – Nguồn Dữ liệu

Hệ thống thu thập dữ liệu từ nhiều nguồn đa dạng theo mô hình Multi-Source Data Collection, bao gồm các nền tảng đặt phòng trực tuyến (OTA) như Booking.com, Agoda, dữ liệu đánh giá từ Google Maps Reviews và các nguồn bổ sung khác. Đây là tầng đầu vào của toàn bộ pipeline, cung cấp dữ liệu thô về thông tin khách sạn, giá phòng, tiện ích và đánh giá của khách hàng tại khu vực Đà Nẵng. Sự đa dạng về nguồn dữ liệu giúp đảm bảo tính toàn diện và khách quan của thông tin được thu thập, tạo nền tảng vững chắc cho các giai đoạn xử lý và phân tích tiếp theo.

1.2.2. Ingestion – Thu thập và Phân tích Dữ liệu

Lớp thu thập dữ liệu triển khai thành phần Scraper & Parser để tự động cào và phân tích cú pháp dữ liệu từ các nguồn đã xác định. Thành phần này nhận tín hiệu kích hoạt định kỳ từ Cloud Scheduler theo chu kỳ mỗi 24 giờ, đảm bảo dữ liệu luôn được cập nhật liên tục mà không cần can thiệp thủ công. Scraper & Parser đảm nhận đồng thời hai nhiệm vụ: giả lập hành vi người dùng để kích hoạt nội dung động trên các trang web OTA, đồng thời trích xuất và chuyển đổi nội dung HTML đã render thành dữ liệu có cấu trúc. Toàn bộ dữ liệu thu về được đóng gói thành tệp hợp nhất kèm nhãn thời gian của phiên thu thập, sẵn sàng chuyển tiếp sang giai đoạn lưu trữ.

1.2.3. Storage – Lưu trữ Dữ liệu Thô

Google Cloud Storage (GCS) được sử dụng như một Data Lake nhằm lưu giữ toàn bộ dữ liệu nguyên bản (Raw Data) được thu thập từ nguồn. Mục tiêu của lớp này là đảm bảo dữ liệu gốc luôn được bảo toàn trước khi trải qua bất kỳ quá trình biến đổi nào. Việc tách riêng lớp lưu trữ dữ liệu thô cho phép hệ thống tái xử lý khi phát hiện lỗi hoặc khi cần áp dụng các quy tắc ETL mới trong tương lai mà không ảnh hưởng đến dữ liệu nguồn. Cloud Storage đồng thời đóng vai trò điểm trung chuyển dữ liệu sang giai đoạn xử lý tiếp theo, hình thành một kho dữ liệu trung tâm ổn định và có khả năng mở rộng cho toàn bộ hệ thống.

1.2.4. Processing – Xử lý và Biến đổi Dữ liệu

Lớp xử lý dữ liệu được triển khai theo cơ chế Build & Deploy gồm ba thành phần phối hợp chặt chẽ. Source Code ETL (Python, SQL, Config, v.v.) được đóng

gói thành Docker Image và lưu trữ vào Artifact Registry. Khi nhận tín hiệu kích hoạt, Cloud Run Job kéo image từ Artifact Registry để khởi tạo container tạm thời thực thi toàn bộ quy trình Data Cleaning & Transformation. Quy trình ETL bao gồm ba giai đoạn tuần tự: trích xuất dữ liệu thô từ Cloud Storage, biến đổi và chuẩn hóa dữ liệu bao gồm xử lý mã hóa tiếng Việt, loại bỏ trùng lặp, sinh khóa định danh và phân tách thành các bảng chuyên biệt, sau đó nạp dữ liệu vào các hệ thống lưu trữ đích. Toàn bộ tài nguyên container được giải phóng ngay sau khi hoàn thành, đảm bảo mô hình Serverless hoàn toàn và tối ưu chi phí vận hành.

1.2.5. Data Warehouse – Kho Dữ liệu Tập trung

Hệ thống sử dụng kiến trúc lưu trữ đa tầng nhằm phục vụ đồng thời hai nhu cầu khác biệt về truy vấn dữ liệu. Cloud SQL (PostgreSQL) đóng vai trò cơ sở dữ liệu tác nghiệp (OLTP), lưu trữ Operational Data và phục vụ các truy vấn thời gian thực của AI Agent với độ trễ thấp. Google BigQuery đóng vai trò kho dữ liệu phân tích (OLAP), lưu trữ Analytics Data theo cấu trúc tối ưu cho các truy vấn tổng hợp trên khối lượng dữ liệu lớn, phục vụ trực tiếp cho Looker Studio Dashboard. Kiến trúc phân tầng này đảm bảo hệ thống đáp ứng được cả yêu cầu vận hành tức thời lẫn nhu cầu phân tích nghiệp vụ chuyên sâu từ một nguồn dữ liệu thống nhất và đáng tin cậy.

1.2.6. Consumption – Khai thác và Trình bày Dữ liệu

Lớp khai thác dữ liệu bao gồm hai kênh phục vụ người dùng cuối song song. AI Agent (Gemini on Vertex AI) cung cấp khả năng xử lý ngôn ngữ tự nhiên dưới dạng Smart Travel Assistant, kết nối trực tiếp với Cloud SQL để truy vấn dữ liệu vận hành theo thời gian thực và phản hồi các câu hỏi của người dùng về thông tin khách sạn, giá phòng, tiện ích và đánh giá tại Đà Nẵng. Looker Studio kết nối trực tiếp với BigQuery để xây dựng các Reports & Visualization, bao gồm dashboard phân tích xu hướng biến động giá phòng và mức độ hài lòng của khách hàng theo từng khía cạnh dịch vụ. Sự kết hợp giữa tư vấn thông minh và trực quan hóa dữ liệu giúp chuyển hóa toàn bộ dữ liệu khách sạn thành thông tin hỗ trợ ra quyết định, nâng cao trải nghiệm lựa chọn lưu trú cho du khách tại Đà Nẵng.

2. Mô tả dữ liệu

2.1. Nguồn gốc dữ liệu

Dữ liệu sử dụng trong dự án được khai thác đa nguồn từ hai nền tảng thương mại điện tử du lịch trực tuyến hàng đầu hiện nay là Booking.com và Agoda. Quy trình thu thập dữ liệu được thực hiện hoàn toàn tự động thông qua hệ thống Data Pipeline do nhóm phát triển.

2.2. Phạm vi dữ liệu

Phạm vi không gian: Tập dữ liệu giới hạn nghiêm ngặt trong ranh giới hành chính của Thành phố Đà Nẵng (bao gồm các quận Hải Châu, Thanh Khê, Sơn Trà, Ngũ Hành Sơn, Liên Chiểu, Cẩm Lệ và huyện Hòa Vang). Trong đó, trọng tâm dữ liệu tập trung sâu vào các khu vực trọng điểm du lịch, có mật độ lưu trú đậm đặc như dải ven biển Mỹ Khê và dọc hai bên bờ sông Hàn.

Phạm vi đối tượng: Khảo sát toàn bộ các cơ sở lưu trú đang vận hành và có hiển thị trên nền tảng Booking.com và Agoda tại Đà Nẵng, bao gồm các loại hình: Khách sạn (tiêu chuẩn từ 1 đến 5 sao), Căn hộ dịch vụ, Homestay, Biệt thự du lịch và Resort nghỉ dưỡng.

Độ mịn dữ liệu: Mức độ chi tiết thấp nhất của dữ liệu (Atomic Grain) được định danh thông qua mã phiên giá phòng, được xác định cụ thể theo thực thể: Mức giá của một loại phòng cụ thể, thuộc một cơ sở lưu trú cụ thể, tại một ngày nhận phòng và ngày trả phòng cụ thể, tương ứng với một mốc thời gian trích xuất dữ liệu cố định.

2.3. Các thành phần dữ liệu thu thập

Thông tin định danh và thuộc tính cơ sở: Nhóm thông tin này chịu trách nhiệm lưu trữ các dữ liệu mang tính cố định hoặc ít biến động của cơ sở lưu trú, bao gồm tên gọi chính thức, mã định danh hệ thống, đoạn văn bản mô tả giới hạn, phân loại hình thức lưu trú, xếp hạng sao tiêu chuẩn và khung thời gian nhận/trả phòng quy định. Ngoài ra, nhóm thuộc tính này còn hệ thống hóa danh mục các tiện ích đi kèm (như hồ bơi, bãi đỗ xe, dịch vụ đưa đón sân bay, cho phép mang vật nuôi) dưới dạng các biến nhị phân phục vụ cho bộ lọc dịch vụ.

Thông tin không gian và địa lý: Thành phần cốt lõi bao gồm địa chỉ hành chính chi tiết và tọa độ định vị toàn cầu (Vĩ độ - Latitude và Kinh độ - Longitude) của

khách sạn. Từ dữ liệu gốc này, hệ thống thực hiện đồng bộ, tính toán và quy đổi khoảng cách thực tế về đơn vị mét kết hợp với việc xếp hạng khoảng cách từ cơ sở lưu trú tới các địa điểm lân cận hoặc danh thắng trọng điểm của thành phố (Bãi biển Mỹ Khê, Sông Hàn, Sân bay Quốc tế Đà Nẵng) nhằm phục vụ trực tiếp cho thuật toán đề xuất vị trí tối ưu của du khách.

Thông tin cấu trúc hạng phòng: Mô tả chi tiết cấu trúc sản phẩm thương mại bên trong một cơ sở lưu trú, bao gồm mã định danh loại phòng, tên gọi hạng phòng, đặc tả cấu trúc giường ngủ (giường đơn, giường đôi lớn) và giới hạn số lượng khách lưu trú tối đa được phép quy định trên mỗi phòng.

Thông tin đánh giá và danh tiếng: Phản ánh chất lượng dịch vụ chứng thực thông qua trải nghiệm thực tế của khách hàng đã lưu trú, bao gồm tổng số lượng bài đánh giá hiện có trên hệ thống và điểm số đánh giá trung bình tổng thể (thang điểm 10). Đặc biệt, thành phần này phân rã sâu hệ thống điểm số chi tiết cho từng khía cạnh trải nghiệm bao gồm: độ sạch sẽ, mức độ thoải mái, sự thuận tiện của vị trí, thái độ phục vụ của nhân viên, chất lượng kết nối Wi-Fi và mức độ đáng giá tiền so với chi phí bỏ ra.

Dữ liệu thương mại biến động: Lưu trữ các số liệu đo lường định lượng và động phục vụ trực tiếp cho việc tính toán của bảng Fact. Nhóm dữ liệu này bao gồm mức giá niêm yết gốc khi chưa áp dụng ưu đãi, mức giá thực tế du khách phải thanh toán tại thời điểm trích xuất dữ liệu, số tiền chênh lệch được giảm trừ trực tiếp, cờ trạng thái xác định mức giá đã bao gồm thuế/phí dịch vụ phát sinh hay chưa, cùng thông tin cụ thể về ngày nhận phòng và ngày trả phòng dự kiến của phiên tra cứu giá.

Tên cột	Kiểu dữ liệu	Mô tả chi tiết	Ví dụ dữ liệu
hotel_id	VARCHAR	Mã định danh duy nhất của khách sạn trên hệ thống (Natural Key từ URL	muong-thanh-luxury-da-nang

		Booking/Agoda)	
hotel_name	VARCHAR	Tên chính thức hiển thị của cơ sở lưu trú	Muong Thanh Luxury Da Nang Hotel
description	TEXT	Đoạn văn bản mô tả ngắn hoặc giới thiệu chung về khách sạn	Khách sạn nằm bên bờ biển Mỹ Khê...
stars_rating	INTEGER	Xếp hạng tiêu chuẩn sao từ 1 đến 5 sao (0 hoặc NULL nếu là Homestay/Căn hộ)	5
property_type	VARCHAR	Loại hình cơ sở lưu trú (Hotel, Apartment, Homestay, Resort)	Hotel
popular_facilities	TEXT	Chuỗi danh sách các tiện ích phổ biến nổi bật hiển thị ở trang đầu	Hồ bơi, Chỗ đỗ xe miễn phí, Wi-Fi
facility_name	VARCHAR	Tên của một tiện ích cụ thể nằm trong danh	Airport shuttle

		mục tiện ích chi tiết	
street_address	TEXT	Tên đường và số nhà cụ thể của khách sạn	270 Võ Nguyên Giáp
city	VARCHAR	Thành phố nơi khách sạn tọa lạc	Đà Nẵng
country	VARCHAR	Quốc gia	Việt Nam
full_address	TEXT	Địa chỉ đầy đủ được chuẩn hóa ghi trên hệ thống	270 Võ Nguyên Giáp, Mỹ An, Ngũ Hành Sơn, Đà Nẵng
latitude	NUMERIC	Vĩ độ GPS phục vụ định vị bản đồ và tính toán không gian	1.605.445.600
longitude	NUMERIC	Kinh độ GPS phục vụ định vị bản đồ và tính toán không gian	10.824.832.100
place_name	VARCHAR	Tên của địa điểm lân cận hoặc điểm tham quan quan trọng (POI)	Bãi biển Mỹ Khê
place_type	VARCHAR	Phân loại điểm lân cận (attraction,	beach

		nature, airport, restaurant, beach, transport)	
distance_value	NUMERIC	Giá trị khoảng cách thô hiển thị trên trang web	150.00
distance_unit	VARCHAR	Đơn vị đo khoảng cách hiển thị	m
distance_in_meters	INTEGER	Khoảng cách thực tế đã được quy đổi đồng nhất về đơn vị mét	150
distance_rank	INTEGER	Thứ hạng khoảng cách từ khách sạn tới địa điểm lân cận (gần nhất là 1)	1
review_id	VARCHAR	Mã định danh duy nhất của bản ghi tóm tắt đánh giá	REV-8501-2026
review_count	INTEGER	Tổng số lượng bài đánh giá, bình luận hiện có từ du khách	1420
average_score	NUMERIC	Điểm đánh giá trung bình	8.8

		tổng thể tổng hợp từ khách hàng (Thang 10)	
staff_score	NUMERIC	Điểm số đánh giá chi tiết về thái độ phục vụ của nhân viên	8.7
facilities_score	NUMERIC	Điểm số đánh giá chi tiết về cơ sở vật chất, tiện ngi	8.6
cleanliness_score	NUMERIC	Điểm số đánh giá chi tiết về mức độ vệ sinh và sạch sẽ	9.0
comfort_score	NUMERIC	Điểm số đánh giá chi tiết về độ thoải mái của không gian phòng	8.9
value_for_money_score	NUMERIC	Điểm số đánh giá mức độ đáng giá tiền so với chi phí bỏ ra	8.5
location_score	NUMERIC	Điểm số đánh giá riêng về mức độ thuận tiện của vị trí khách sạn	9.4

free_wifi_score	NUMERIC	Điểm số đánh giá chi tiết về chất lượng kết nối Wi-Fi miễn phí	8.3
room_type_id	VARCHAR	Mã định danh duy nhất của từng loại phòng trong một khách sạn	RT-MT-DELUXE-OCEAN
room_type_name	VARCHAR	Tên gọi chính thức của hạng phòng trên hệ thống	Deluxe Double Room with Ocean View
bed_types	VARCHAR	Cấu trúc và số lượng giường được trang bị trong phòng	1 giường đôi lớn
max_guests	INTEGER	Số lượng khách tối đa được phép lưu trú quy định trên phòng	2
checkin_time_start	VARCHAR	Mốc thời gian bắt đầu cho phép khách thực hiện nhận phòng	14:00
checkin_time_end	VARCHAR	Mốc thời gian giới hạn kết thúc	00:00

		việc nhận phòng trong ngày	
checkout_time_start	VARCHAR	Mốc thời gian sớm nhất khách có thể làm thủ tục trả phòng	06:00
checkout_time_end	VARCHAR	Mốc thời gian giới hạn tối đa khách phải hoàn tất trả phòng	12:00
booking_id	VARCHAR	Mã định danh duy nhất cho phiên giá phòng được ghi nhận	BK-20260606-8501-402
original_price	NUMERIC	Mức giá niêm yết gốc của phòng khi chưa áp dụng ưu đãi (VNĐ)	1500000.00
current_price	NUMERIC	Mức giá thực tế tại thời điểm chào mà du khách phải thanh toán (VNĐ)	1200000.00
discount	NUMERIC	Số tiền được giảm trừ trực tiếp (Chênh lệch giữa giá gốc và giá thực tế)	300000.00

taxes_included	INTEGER	Cờ trạng thái xác định mức giá đã bao gồm thuế/phí dịch vụ chưa (1: Rồi, 0: Chưa)	1
extracted_at	TIMESTAMP	Mốc mốc thời gian hệ thống tự động thực hiện hành động cào bản ghi này	2026-06-06 01:05:23
checkin_date	DATE	Ngày dự kiến nhận phòng của phiên tra cứu giá	2026-06-15
checkout_date	DATE	Ngày dự kiến trả phòng của phiên tra cứu giá	2026-06-16

3. Kết quả thực hiện

3.1. Cào dữ liệu

Để thu thập dữ liệu từ hai nền tảng Booking.com và Agoda, hệ thống triển khai một giải pháp cào dữ liệu tối ưu kết hợp giữa Fire Crawl API và công cụ giả lập hành vi người dùng Selenium WebDriver. Cách thức thực hiện quy trình này được chia thành 3 giai đoạn chính bao gồm:

3.1.1. Giai đoạn 1: Giả lập và Tương tác động bằng Selenium


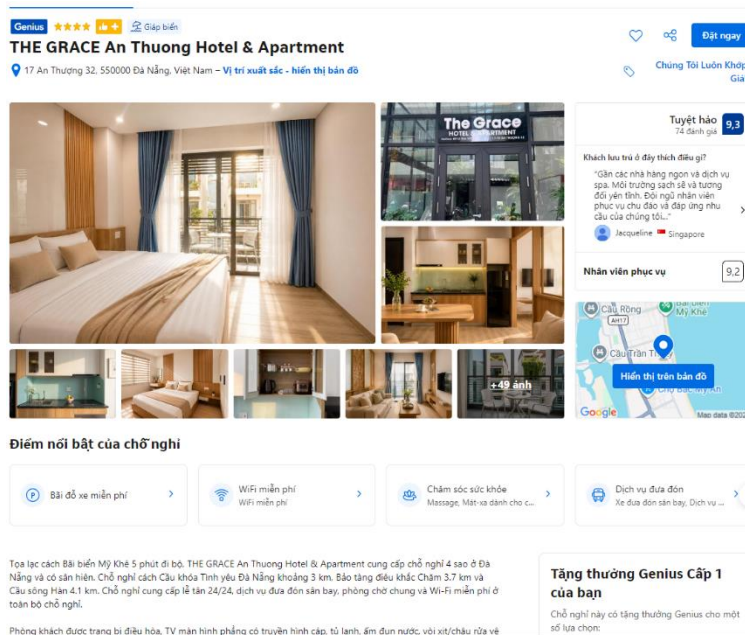
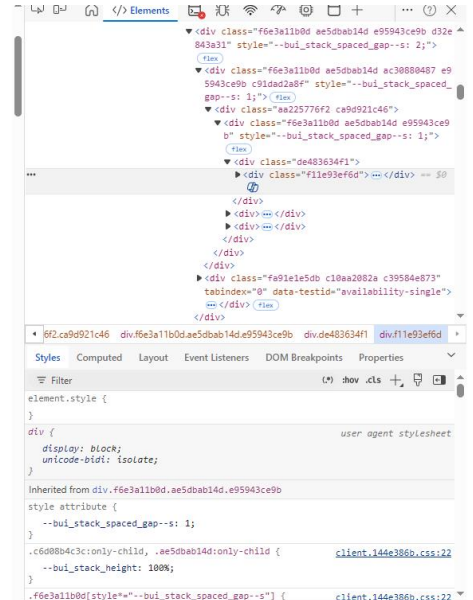

Mục tiêu: Vượt qua các cơ chế kết xuất trang bằng mã nguồn JavaScript của Booking và Agoda.

Cách thức thực hiện:

Trình duyệt tự động truy cập vào các URL danh sách khách sạn tại khu vực Đà Nẵng. Selenium thực hiện các hành động giả lập như một người dùng thực tế: tự

động cuộn trang để tải thêm phòng trống, click vào các nút phân trang, và chọn các bộ lọc cấu hình ngày nhận/trả phòng dự kiến.

Hành động này giúp kích hoạt toàn bộ mã JavaScript trên trang nguồn, ép hệ thống hiển thị đầy đủ thông tin về giá phòng, chính sách hủy phòng và danh sách bài đánh giá vốn chỉ xuất hiện khi có tương tác của người dùng.




3.1.2. Giai đoạn 2: Trích xuất cấu trúc HTML qua File Crawl API

Mục tiêu: Thu thập toàn bộ nội dung mã nguồn của trang web sau khi đã render đầy đủ một cách nhanh chóng và tối ưu hóa việc phân tách dữ liệu.

Cách thức thực hiện:

Sau khi Selenium hoàn tất việc tương tác và tải toàn bộ trang web, hệ thống sử dụng dịch vụ Firecrawl API chuyên dụng cho Data Scraper để quét qua cấu trúc cây thư mục DOM của trang HTML.



Firecrawl API hỗ trợ chuyển đổi mã nguồn HTML động vừa tải về thành dạng dữ liệu có cấu trúc sạch sẽ Markdown hoặc JSON thô, giúp cô lập các thẻ chứa dữ liệu như thông tin tên khách sạn, tọa độ GPS, khối điểm số đánh giá và cấu trúc giá cả ra khỏi các đoạn mã giao diện thừa đồng thời tải toàn bộ cấu trúc html của 1 trang khách sạn về phục vụ cho quá trình trích xuất thông tin.

The screenshot shows a code editor interface. On the left, a file explorer lists several HTML files under the 'hotels' directory, with '7seven-sea.html' selected. The main editor area displays the raw HTML content of this file, showing various tags and attributes, including a meta tag for the page title and a link to the Booking.com website.

Giải pháp này làm giảm thiểu đáng kể dung lượng tệp tin rác và tăng tốc độ xử lý cho đường ống, đồng thời giúp bóc tách văn bản review phi cấu trúc một cách chính xác tuyệt đối để chuẩn bị làm nguyên liệu cho tầng AI.

3.1.3. Giai đoạn 3: Đóng gói và lưu dữ liệu

Mục tiêu: Đóng gói dữ liệu đạt độ mịn thấp nhất (Data Grain) và đẩy về vùng lưu trữ thô.

Cách thức thực hiện:

```
{
  "hotel_id": "389-hz-homestay",
  "hotel_name": "389 Hz Homestay",
  "canonical_url": "https://www.booking.com/hotel/vn/389-hz-homestay.vi.html",
  "stars_rating": "2 trên 5 sao",
  "stars_rating_value": 2,
  "latitude": 16.0635697,
  "longitude": 108.2156326,
  "review_score": 9.5,
  "review_count": 2,
  "review_score_word": "Xuất sắc",
  "gia_thap_nhat": 438136.0,
  "gia_cao_nhat": 1431818.0,
  "address": "389 Ông Ích Khiêm, 50000 Đà Nẵng, Việt Nam Vị trí xuất sắc - được cho điểm 10/10! (điểm từ 2 đánh giá) Được",
  "ngay_checkin": "2026-07-06",
  "ngay_checkout": "2026-07-07",
  "popular_facilities": "WiFi miễn phí, Xe đưa đón sân bay, Lễ tân 24 giờ, Phòng không hút thuốc, Phòng gia đình, Chỗ đỗ",
  "description": "Nằm tại vị trí thuận tiện ở trung tâm Đà Nẵng, 389 Hz Homestay cách Bảo tàng điêu khắc Chăm 12 phút đi",
  "hotel_policies": "Quy tắc chung\nNhận phòng\nTừ 14:00 - 23:00\nTrả phòng\nTừ 06:00 - 12:00\nHủy đặt phòng\n/ Trà trước",
  "whats_nearby": null,
  "top_attractions": "Bảo tàng điêu khắc Chăm 1 km; Cầu Rồng 1,3 km; Cầu khóa Tình yêu Đà Nẵng 2 km; Cầu sông Hàn 2 km; C",
  "natural_beauty": "Núi Ngũ Hành Sơn/ Núi Non Nước 5 km",
  "nearest_airports": "Sân bay Quốc tế Đà Nẵng 2,3 km; Sân bay quốc tế Phú Bài 79 km; Sân bay Chu Lai 95 km",
  "restaurants_cafes": "Cafe/quán bar Monaco Coffee 300 m; Nhà hàng Bé My 350 m; Nhà hàng Quán 504 100 m",
  "beaches_in_area": "Bãi biển Thanh Bình 3,1 km; Bãi biển Mỹ Khê 3,6 km; Bãi biển Xuân Thiều 5 km; Bãi biển Bắc Mỹ An 5",
  "public_transport": "Xe buýt Bến xe Buýt 5 km",
  "staff_score": 10.0,
  "facilities_score": 10.0,
  "cleanliness_score": 10.0,
  "comfort_score": 10.0,
  "value_for_money_score": 10.0,
  "location_score": 10.0,
```

Toàn bộ dữ liệu thu về từ Fire Crawl API được cấu trúc lại dưới dạng tệp tin JSON phẳng hợp nhất. Mỗi bản ghi sẽ chứa trọn vẹn thông tin từ định danh khách sạn, địa chỉ vị trí, cấu trúc phòng, giá phòng, điểm số đánh giá kèm nhãn thời gian vật lý của phiên cào. Tệp tin JSON này lập tức được đẩy thẳng vào một Bucket lưu trữ trên Google Cloud Storage.

3.2. Lưu trữ dữ liệu thô

Sau quá trình thu thập dữ liệu từ các nguồn phục vụ bài toán gợi ý khách sạn tại Đà Nẵng, nhóm tiến hành lưu trữ dữ liệu thô trên nền tảng đám mây nhằm tạo nguồn dữ liệu đầu vào tập trung cho toàn bộ pipeline xử lý. Việc tách riêng lớp

dữ liệu thô giúp hệ thống dễ quản lý hơn, đồng thời tạo điều kiện thuận lợi cho các bước tiền xử lý, chuẩn hóa và nạp dữ liệu ở các giai đoạn tiếp theo.

Trong bước lưu trữ dữ liệu thô, dữ liệu sau khi được crawl từ các nguồn thu thập được tổng hợp thành tệp `raw_hotels_full.csv`. Tệp dữ liệu này sau đó được tải lên Google Cloud Storage để hình thành vùng lưu trữ đầu vào tập trung cho pipeline ETL. Toàn bộ quá trình tạo bucket, cấu hình vùng lưu trữ và tải dữ liệu được thực hiện thông qua Google Cloud Console trong dự án CAPSTONE PROJECT 2 GROUP 4, làm cơ sở cho các bước tiền xử lý và nạp dữ liệu tiếp theo.

Quy trình lưu trữ dữ liệu thô trên nền tảng Google Cloud được nhóm thực hiện theo các bước sau:

Nom	Création	Type d'emplacement	Zone	Classe de stockage par défaut	Dernière modification	Accès public	Co
capstone-project-2-group-4-data	24 juin 2026, 19:26:49	Region	asia-southeast1	Standard	24 juin 2026, 19:26:49	Soumise à des LCA au niveau de l'objet	Un
capstone-project-2-group-4-cloudbuild	24 juin 2026, 18:46:04	Multi-region	us	Standard	24 juin 2026, 18:46:04	Soumise à des LCA au niveau de l'objet	Un
run-sources-capstone-project-2-group-4	24 juin 2026, 17:55:47	Region	asia-southeast1	Standard	24 juin 2026, 17:55:47	Non public	Un

Bước 1. Truy cập dịch vụ lưu trữ

Nhóm đăng nhập vào dự án CAPSTONE PROJECT 2 GROUP 4 trên Google Cloud Console, sau đó truy cập dịch vụ Cloud Storage để bắt đầu thiết lập khu vực lưu trữ dữ liệu thô.

Bước 2. Tạo bucket lưu trữ


Tại giao diện Cloud Storage, nhóm tạo một bucket mới với tên `capstone-project-2-group-4-data`. Đây là bucket được sử dụng để lưu trữ dữ liệu đầu vào của hệ thống.

Bước 3. Cấu hình thông số lưu trữ

Trong quá trình tạo bucket, nhóm lựa chọn loại vị trí Region, khu vực triển khai `asia-southeast1` và lớp lưu trữ mặc định `Standard`. Việc lựa chọn các thông số này nhằm đảm bảo sự đồng bộ với các dịch vụ khác trong hệ thống và đáp ứng nhu cầu truy xuất dữ liệu thường xuyên trong pipeline ETL.

Bước 4. Tải dữ liệu thô lên hệ thống

Sau khi bucket được khởi tạo thành công, nhóm tiến hành tải tệp dữ liệu thô `raw_hotels_full.csv` từ máy cục bộ lên bucket `capstone-project-2-group-4-data` thông qua giao diện Google Cloud Console.



Kết quả đạt được:

Kết quả thực hiện cho thấy nhóm đã tạo thành công bucket `capstone-project-2-group-4-data` trên hệ thống Google Cloud Storage. Bucket được triển khai tại khu vực `asia-southeast1` với lớp lưu trữ mặc định là `Standard`. Đồng thời, tệp dữ liệu thô `raw_hotels_full.csv` cũng đã được tải lên thành công và sẵn sàng phục vụ cho các bước xử lý tiếp theo. Việc hoàn thành bước lưu trữ dữ liệu thô đã giúp hình thành một vùng dữ liệu đầu vào tập trung, ổn định và có khả năng mở rộng. Dữ liệu tại đây được sử dụng cho các bước làm sạch, biến đổi và nạp vào cơ sở dữ liệu trong quy trình ETL.

3.3. ETL

Dữ liệu thu thập từ các nền tảng OTA (Online Travel Agency) như Booking.com thường tồn tại ở dạng phi cấu trúc hoặc bán cấu trúc, chứa nhiều nhiễu, lỗi mã hóa font chữ tiếng Việt và khó khăn trong việc liên kết giữa các cơ sở dữ liệu quan hệ. Để giải quyết bài toán này, dự án thiết lập Serverless ETL Pipeline hoàn chỉnh nhằm tự động hóa quá trình trích xuất (Extract), biến đổi (Transform) và nạp (Load) dữ liệu khách sạn Đà Nẵng

Kiến trúc vật lý của hệ thống tuân thủ nguyên lý tách biệt giữa Tính toán (Compute) và Lưu trữ (Storage). Nguyên lý này mang lại ba lợi ích cốt lõi:

Khả năng co giãn độc lập (Elasticity): Khi dung lượng dữ liệu tăng, hệ thống chỉ cần mở rộng lớp lưu trữ của Cloud Storage mà không yêu cầu nâng cấp năng lực tính toán của Cloud Run. Ngược lại, khi cần xử lý biến đổi phức tạp, Cloud Run Jobs có thể tăng tài nguyên CPU/RAM mà không ảnh hưởng tới trạng thái lưu trữ dữ liệu.

Tối ưu hóa chi phí (Cost Efficiency): Lưu trữ trên GCS có chi phí cực thấp. Tiến trình tính toán chỉ chạy trong thời gian phát sinh tác vụ ngắn và tự động giải phóng tài nguyên ngay lập tức, giúp tránh chi phí duy trì phần cứng nhàn rỗi.

Chịu lỗi và Cô lập tài nguyên (Fault Isolation): Nếu xảy ra lỗi ứng dụng hoặc tiến trình ETL, dữ liệu thô nằm trong Cloud Storage vẫn được bảo toàn. Việc tách biệt giữa lớp xử lý và lớp lưu trữ giúp giảm thiểu rủi ro mất dữ liệu và tăng khả năng khôi phục hệ thống.

3.3.1. Extract (Trích xuất dữ liệu)

Giai đoạn trích xuất (Extract) thực chất là quá trình di chuyển file dữ liệu thô từ kho lưu trữ đám mây vào trong bộ nhớ của chương trình để chuẩn bị cho các bước xử lý tiếp theo. Có thể hình dung đây là quá trình lấy một tập tài liệu từ kho lưu trữ và đặt lên bàn làm việc để bắt đầu xử lý.

Bước 1: Lưu trữ dữ liệu gốc (Cloud Storage)

Tập dữ liệu khách sạn sau khi thu thập (raw_hotels_full.csv) được lưu trữ an toàn trên Google Cloud Storage. Đây là nơi lưu trữ trung tâm, đóng vai trò như một "kho hồ sơ" chứa toàn bộ dữ liệu gốc của hệ thống.

Bước 2: Tải dữ liệu về môi trường xử lý (Container)

Sau khi dữ liệu thô được lưu trữ trên Cloud Storage, hệ thống cần một môi trường tính toán để thực hiện các tác vụ ETL. Trong dự án này, môi trường xử lý được triển khai dưới dạng Cloud Run Job chạy trên nền tảng container.

Mã nguồn ETL được đóng gói thành Docker Image và lưu trữ trong Artifact Registry. Repository `danang-etl-job` được sử dụng để quản lý các phiên bản Docker Image của dịch vụ ETL. Khi Cloud Run Job được kích hoạt, hệ thống sẽ tự động lấy image mới nhất từ Repository này để khởi tạo môi trường xử lý.

```
def download_from_gcs(bucket_name, source_blob_name, destination_file_path):
    """Tải file từ Google Cloud Storage bucket về thư mục cục bộ"""
    try:
        # Client tự động dùng quyền IAM của Service Account khi chạy trên Cloud Run Job
        storage_client = storage.Client()
        bucket = storage_client.bucket(bucket_name)
        blob = bucket.blob(source_blob_name)

        print(f"Đang tải gs://{bucket_name}/{source_blob_name} xuống {destination_file_path}.")
        blob.download_to_filename(destination_file_path)
        print("Tải file từ GCS thành công!")
        return True
    except Exception as e:
        print(f"Không thể tải file từ GCS: {e}")
        return False

# Cấu hình tải dữ liệu thô từ GCS
bucket_name = os.environ.get("GCS_BUCKET_NAME", "capstone-project-2-group-4-data")
source_blob_name = "raw_hotels_full.csv"
raw_path = os.path.join(base_dir, "raw_hotels_full.csv")

-
FROM python:3.10-slim
WORKDIR /app

# Sao chép các tệp yêu cầu thư viện từ thư mục etl/
COPY etl/requirements_etl.txt .
RUN pip install --no-cache-dir -r requirements_etl.txt

# Sao chép mã nguồn ETL từ thư mục etl/
COPY etl/preprocess.py .
COPY etl/load_to_cloud_sql.py .
COPY etl/run_etl.py .

# Sao chép tệp dữ liệu CSV từ thư mục data/
COPY data/raw_hotels_full.csv .

CMD ["python", "run_etl.py"]
```

Repository Details

Format

Docker

Type

Standard

▼

Show more

Filter

Enter property name or value

☐	Name ↑	Connection	Created	Updated
☐	 danang-agent-service	—	1 day ago	23 hours ago
☐	 danang-etl-job	—	1 day ago	1 day ago

Khi người dùng nhấn Execute hoặc khi Cloud Scheduler kích hoạt Job theo lịch, Cloud Run sẽ thực hiện các bước sau:

Truy xuất Docker Image từ Artifact Registry.

Khởi tạo một container tạm thời (ephemeral container).

Cấp phát CPU, RAM và không gian lưu trữ tạm thời cho container.

Thực thi chương trình Python được định nghĩa trong image.

Tại thời điểm này container chỉ mới chứa mã nguồn ETL, chưa có dữ liệu để xử lý. Chương trình sử dụng thư viện Google Cloud Storage Client để kết nối tới Bucket `gs://danang-hotels-raw-data` và tải tệp dữ liệu `raw_hotels_full.csv` từ Cloud Storage xuống môi trường thực thi của container để chuẩn bị cho quá trình ETL

Cloud Run sử dụng mô hình container tạm thời (ephemeral container), nghĩa là môi trường thực thi chỉ tồn tại trong thời gian Job đang hoạt động. Sau khi tiến trình ETL hoàn tất, toàn bộ tài nguyên tính toán như CPU, RAM và vùng lưu trữ tạm thời của container sẽ được tự động giải phóng. Trong khi đó, dữ liệu nguồn vẫn được lưu trữ an toàn trên Google Cloud Storage, đảm bảo khả năng tái sử dụng và khôi phục khi cần thiết.

Job: danang-etl-job

Region: asia-southeast1

Last updated: Jun 24, 2026, 8:13:21 PM

History

Observability

Triggers

YAML

Filter

Filter history

	Execution ID	Creation time ↓	Tasks	End time	Actions
	danang-etl-job-rjkmd	Jun 26, 2026, 12:00:03 AM	1/1 completed	Jun 26, 2026, 12:00:21 AM	
	danang-etl-job-9x2fw	Jun 25, 2026, 12:00:00 AM	1/1 completed	Jun 25, 2026, 12:00:25 AM	
	danang-etl-job-vt24j	Jun 24, 2026, 8:13:28 PM	1/1 completed	Jun 24, 2026, 8:14:02 PM	

danang-etl-job-rjkmd

Executed by mcp-toolbox-sa@capstone-project-2-group-4.iam.gserviceaccount.com

Tasks overview (1):

1 Succeeded

0 Failed

0 Running

Tasks

Containers

Networking

Security

YAML

Filter

Filter tasks

	Task ↑	Last exit code ⓘ	Retries	Start time	End time	
	0	0	0	Jun 26, 2026, 12:00:09 AM	Jun 26, 2026, 12:00:18 AM	View

Bước 3: Nạp dữ liệu vào RAM (Pandas DataFrame)
 Sau khi tệp dữ liệu được tải từ Cloud Storage xuống container, chương trình Python bên trong Docker Image sẽ được thực thi. Môi trường chạy đã được cấu hình sẵn các thư viện cần thiết như Pandas, NumPy và Google Cloud SDK. Chương trình sử dụng Pandas để đọc dữ liệu CSV vào bộ nhớ RAM dưới dạng DataFrame:

DataFrame là cấu trúc dữ liệu dạng bảng được lưu trong bộ nhớ, cho phép thực hiện các thao tác làm sạch, chuẩn hóa, chuyển đổi kiểu dữ liệu và biến đổi dữ liệu trước khi chuyển sang giai đoạn Transform.

3.3.2. Transform

Sau khi dữ liệu được nạp vào bộ nhớ dưới dạng DataFrame, hệ thống thực hiện giai đoạn Transform nhằm chuyển đổi dữ liệu thô thành dữ liệu có cấu trúc, nhất quán và sẵn sàng cho việc lưu trữ trong cơ sở dữ liệu quan hệ. Toàn bộ quá trình được triển khai trong module preprocess.py.

Mục tiêu của giai đoạn này gồm:

Làm sạch dữ liệu nhiễu và không đồng nhất.

Chuẩn hóa định dạng dữ liệu tiếng Việt.

Tạo khóa định danh duy nhất cho các thực thể.

Trích xuất thông tin từ các trường văn bản tự do.

Tối ưu cấu trúc dữ liệu phục vụ truy vấn và AI Agent.

Các thao tác trong quá trình Transform ngoài việc xử lý duplicate, missing value ra còn tiền xử lý các:

Chuẩn hóa văn bản Unicode NFC

Dữ liệu thu thập từ Booking.com thường chứa các ký tự tiếng Việt ở nhiều chuẩn mã hóa khác nhau. Điều này có thể dẫn đến lỗi tìm kiếm, đối sánh chuỗi hoặc sinh khóa định danh không chính xác.

Hệ thống sử dụng chuẩn Unicode NFC (Canonical Composition) để đưa các ký tự về cùng một dạng biểu diễn thống nhất trước khi xử lý. Bước này giúp đảm bảo tính nhất quán của dữ liệu và nâng cao độ chính xác trong quá trình phân tích.

```
import unicodedata

text = unicodedata.normalize('NFC', text)
```

Sinh khóa định danh xác thực (Deterministic ID Generation)

Nguồn dữ liệu gốc không cung cấp khóa chính ổn định cho nhiều thực thể như loại phòng hoặc tiện ích khách sạn. Vì vậy hệ thống xây dựng các khóa định danh duy nhất dựa trên tập thuộc tính nghiệp vụ.

Ví dụ, khóa `room_type_id` được tạo từ mã khách sạn, tên loại phòng và chỉ số phân biệt. Phương pháp này giúp tránh trùng lặp dữ liệu và đảm bảo tính idempotent khi pipeline được thực thi nhiều lần.

```
import re

text = re.sub(r'^a-z0-9', '_', clean_vietnamese(room_type))

room_type_id = f"{hotel_id}_{text}_{index}"
```

Trích xuất thông tin bằng Biểu thức chính quy (Regex Parsing)

Một số thuộc tính trong dữ liệu nguồn được biểu diễn dưới dạng văn bản tự do như khoảng cách đến địa điểm, thời gian di chuyển hoặc thông tin vị trí.

Hệ thống sử dụng Regular Expression (Regex) để nhận diện và trích xuất các giá trị cần thiết, đồng thời chuyển đổi về định dạng chuẩn phục vụ lưu trữ và tính toán. Ví dụ, khoảng cách "1,2 km" sẽ được chuyển đổi thành giá trị số 1200 mét.

```
import re

match = re.search(r'([\d,.]*)\s*(km|m)', distance_text)

if match:
    value, unit = match.groups()
    distance_in_meters = float(value.replace(',', '.')) * 1000 if unit == 'km' else float(value)
```

Phân nhóm và Xếp hạng địa lý (Geographic Ranking)

Đối với dữ liệu các địa điểm lân cận khách sạn, hệ thống thực hiện phân nhóm theo khách sạn và loại địa điểm, sau đó sắp xếp theo khoảng cách tăng dần.

Kết quả tạo ra trường `distance_rank`, cho phép xác định nhanh các địa điểm gần nhất đối với từng khách sạn. Thông tin này được sử dụng để tối ưu truy vấn phân tích và hỗ trợ AI Agent đưa ra các gợi ý lưu trú phù hợp.

Kết quả của giai đoạn Transform là tập dữ liệu đã được làm sạch, chuẩn hóa và cấu trúc hóa hoàn chỉnh. Dữ liệu sau biến đổi đáp ứng các yêu cầu về chất lượng dữ liệu, tính nhất quán và khả năng mở rộng trước khi chuyển sang giai đoạn Load vào hệ quản trị cơ sở dữ liệu.

```
df['distance_rank'] = (  
    df.groupby(['hotel_id', 'place_type'])  
      ['distance_in_meters']  
      .rank(method='first')  
)
```

Sau quá trình tiền xử lý, dữ liệu được phân tách thành các bảng Dimension và Fact độc lập gồm: Dim_Hotel, Dim_Location, Dim_Facility, Dim_NearbyPlaces, Dim_Review, Dim_RoomType và Fact_Booking.

Đồng thời sinh ra các bảng dữ liệu trung gian trong giai đoạn Transform dưới dạng các tệp CSV tạm thời. Các tệp này được sử dụng làm đầu vào cho giai đoạn Load trước khi dữ liệu được nạp vào Cloud SQL và BigQuery, đóng vai trò là lớp dữ liệu trung gian (Staging Layer) giữa giai đoạn Transform và Load.

```

# 1. Hotels
stars = parse_stars(row.get('stars_rating_value'), row.get('stars_rating'))
checkin_start, checkin_end, checkout_start, checkout_end = extract_policy_times(row.get('hotel_policies'))

hotels_list.append({
    'hotel_id': hid,
    'hotel_name': normalize_text(row.get('hotel_name')),
    'description': normalize_text(row.get('description')),
    'stars_rating': stars,
    'review_count': int(row['review_count']) if not pd.isna(row.get('review_count')) else 0,
    'popular_facilities': normalize_text(row.get('popular_facilities')),
    'property_type': 'Khách sạn',
    'checkin_time_start': checkin_start,
    'checkin_time_end': checkin_end,
    'checkout_time_start': checkout_start,
    'checkout_time_end': checkout_end
})

# 2. Locations
street_addr, city, country, full_addr = parse_address(row.get('address'))
lat = float(row['latitude']) if not pd.isna(row.get('latitude')) else None
lon = float(row['longitude']) if not pd.isna(row.get('longitude')) else None
locations_list.append({
    'hotel_id': hid,
    'street_address': street_addr,
    'city': city,
    'country': country,
    'full_address': full_addr,
    'latitude': lat,
    'longitude': lon
})

# 3. Facilities
facilities_list.extend(parse_facilities(hid, row.get('popular_facilities')))

# 4. Nearby places
nearby_list.extend(parse_nearby_places(hid, row.get('top_attractions'), 'attraction'))
nearby_list.extend((function) parse_nearby_places(hid, row.get('natural_beauty'), 'nature'))
nearby_list.extend(parse_nearby_places(hid, row.get('nearest_airports'), 'airport'))
nearby_list.extend(parse_nearby_places(hid, row.get('restaurants_cafes'), 'restaurant'))
nearby_list.extend(parse_nearby_places(hid, row.get('beaches_in_area'), 'beach'))
nearby_list.extend(parse_nearby_places(hid, row.get('public_transport'), 'transport'))
nearby_list.extend(parse_nearby_places(hid, row.get('whats_nearby'), 'nearby'))

# 5. Reviews
reviews_list.append({
    'review_id': f"{hid}_rev",
    'hotel_id': hid,
    'staff_score': float(row['staff_score']) if not pd.isna(row.get('staff_score')) else 0.0,
    'facilities_score': float(row['facilities_score']) if not pd.isna(row.get('facilities_score')) else 0.0,
    'cleanliness_score': float(row['cleanliness_score']) if not pd.isna(row.get('cleanliness_score')) else 0.0,
    'comfort_score': float(row['comfort_score']) if not pd.isna(row.get('comfort_score')) else 0.0,
    'value_for_money_score': float(row['value_for_money_score']) if not pd.isna(row.get('value_for_money_score')) else 0.0,
    'location_score': float(row['location_score']) if not pd.isna(row.get('location_score')) else 0.0,
    'free_wifi_score': float(row['free_wifi_score']) if not pd.isna(row.get('free_wifi_score')) else 0.0,
    'average_score': float(row['review_score']) if not pd.isna(row.get('review_score')) else 0.0
})

# 6 & 7. Room Types and Room Prices
checkin_date = str(row['ngay_checkin']) if not pd.isna(row.get('ngay_checkin')) else "2026-07-06"
checkout_date = str(row['ngay_checkout']) if not pd.isna(row.get('ngay_checkout')) else "2026-07-07"

```

Việc tách dữ liệu thành các bảng chuyên biệt giúp loại bỏ dư thừa dữ liệu, nâng cao tính nhất quán, đảm bảo khả năng mở rộng và tạo nền tảng cho việc lưu trữ trên PostgreSQL Cloud SQL cũng như phân tích dữ liệu trên BigQuery Data

Warehouse. Sau khi hoàn thành giai đoạn Transform, toàn bộ dữ liệu đã sẵn sàng để chuyển sang giai đoạn Load vào các hệ thống lưu trữ đích.

3.3.3. Load

Sau khi hoàn thành giai đoạn Transform, dữ liệu đã được làm sạch, chuẩn hóa và phân tách thành các bảng Dimension và Fact. Các bảng dữ liệu trung gian này đóng vai trò là đầu vào cho giai đoạn Load, nơi dữ liệu được nạp vào các hệ thống lưu trữ đích nhằm phục vụ cả nhu cầu vận hành nghiệp vụ và phân tích dữ liệu.

Hệ thống sử dụng kiến trúc lưu trữ đa tầng gồm PostgreSQL Cloud SQL và BigQuery Data Warehouse. Trong đó PostgreSQL Cloud SQL đóng vai trò cơ sở dữ liệu tác nghiệp (OLTP), còn BigQuery đóng vai trò kho dữ liệu phân tích (OLAP).

Nạp dữ liệu vào PostgreSQL Cloud SQL

Module `load_to_cloud_sql.py` chịu trách nhiệm kết nối tới PostgreSQL Cloud SQL. Các thông tin cấu hình như địa chỉ máy chủ, cổng kết nối, tên cơ sở dữ liệu và thông tin xác thực được quản lý thông qua biến môi trường của Cloud Run Job.

```
# Cấu hình Database từ biến môi trường (hoặc fallback mặc định)
db_host = os.environ.get("DB_HOST", "136.110.50.188")
db_port = os.environ.get("DB_PORT", "5432")
db_name = os.environ.get("DB_NAME", "postgres")
db_user = os.environ.get("DB_USER", "postgres")
db_password = os.environ.get("DB_PASSWORD", "YourStrongDatabasePassword123")

cleaned_dir = os.path.join(os.path.dirname(os.path.abspath(__file__)), "cleaned_tables")

def get_connection():
    print(f"Đang kết nối tới PostgreSQL tại {db_host}:{db_port}/{db_name} với user: {db_u}")
    return psycopg2.connect(
        host=db_host,
        port=db_port,
        database=db_name,
        user=db_user,
        password=db_password
    )

def load_csv_to_table(cursor, conn, file_name, table_name):
    path = os.path.join(cleaned_dir, file_name)
    if not os.path.exists(path):
        print(f"Không tìm thấy file: {file_name}")
        return

    print(f"Đang import dữ liệu từ {file_name} vào bảng {table_name}...")
    df = pd.read_csv(path)
```

```

# Thực hiện chèn theo lô (batch insert) sau khi chuyển đổi numpy types sang python native
list_records = []
for row in df.iterrows(index=False, name=None):
    clean_row = []
    for val in row:
        if pd.isna(val):
            clean_row.append(None)
        elif isinstance(val, (np.integer, int)):
            clean_row.append(int(val))
        elif isinstance(val, (np.floating, float)):
            clean_row.append(float(val))
        else:
            clean_row.append(val)
    list_records.append(tuple(clean_row))

execute_values(cursor, insert_query, list_records, page_size=1000)
conn.commit()
print(f"Hoàn thành import {len(df)} dòng vào bảng {table_name}.")

try:
    conn = get_connection()
    cursor = conn.cursor()

    # Thực hiện import dữ liệu theo đúng trình tự khóa ngoại (foreign key dependencies)
    load_csv_to_table(cursor, conn, "Dim_Hotel.csv", "hotels")
    load_csv_to_table(cursor, conn, "Dim_Location.csv", "hotel_locations")
    load_csv_to_table(cursor, conn, "Dim_Facility.csv", "hotel_facilities")
    load_csv_to_table(cursor, conn, "Dim_NearbyPlaces.csv", "hotel_nearby_places")
    load_csv_to_table(cursor, conn, "Dim_Review.csv", "hotel_reviews")
    load_csv_to_table(cursor, conn, "Dim_RoomType.csv", "room_types")
    load_csv_to_table(cursor, conn, "Fact_Booking.csv", "room_prices")

    cursor.close()
    conn.close()
    print("Quá trình đẩy dữ liệu lên cơ sở dữ liệu PostgreSQL hoàn tất thành công!")

except Exception as e:
    print("Lỗi xảy ra trong quá trình nạp dữ liệu:", e)

```

Sau khi hoàn thành quá trình làm sạch và chuẩn hóa dữ liệu, các bảng dữ liệu trung gian sẽ được nạp vào Google Cloud SQL sử dụng hệ quản trị cơ sở dữ liệu PostgreSQL. Tại đây, dữ liệu được lưu trữ dưới dạng các bảng quan hệ với các ràng buộc khóa chính (Primary Key) và khóa ngoại (Foreign Key), tạo nền tảng cho việc truy vấn, phân tích và khai thác dữ liệu trong các ứng dụng nghiệp vụ cũng như AI Agent.


table_schema	constraint_name	table_name	column_name	foreign_table_schema	foreign_table_name	foreign_column_name
public	hotel_facilities_hotel_id_fkey	hotel_facilities	hotel_id	public	hotels	hotel_id
public	hotel_locations_hotel_id_fkey	hotel_locations	hotel_id	public	hotels	hotel_id
public	hotel_nearby_places_hotel_id_fkey	hotel_nearby_places	hotel_id	public	hotels	hotel_id
public	hotel_reviews_hotel_id_fkey	hotel_reviews	hotel_id	public	hotels	hotel_id
public	room_prices_hotel_id_fkey	room_prices	hotel_id	public	hotels	hotel_id
public	room_prices_room_type_id_fkey	room_prices	room_type_id	public	room_types	room_type_id
public	room_types_hotel_id_fkey	room_types	hotel_id	public	hotels	hotel_id

Nạp dữ liệu vào BigQuery Data Warehouse

Sau khi dữ liệu được lưu trữ trong PostgreSQL Cloud SQL, hệ thống tiếp tục đồng bộ dữ liệu lên BigQuery Data Warehouse phục vụ các nhu cầu phân tích và trực quan hóa dữ liệu.

```
# Thực hiện nạp song song lên BigQuery Data Warehouse (OLAP)
print("\n=== ĐANG TIẾN HÀNH NẠP DỮ LIỆU LÊN BIGQUERY WAREHOUSE ===")
load_csv_to_bigquery("Dim_Hotel.csv", "hotels")
load_csv_to_bigquery("Dim_Location.csv", "hotel_locations")
load_csv_to_bigquery("Dim_Facility.csv", "hotel_facilities")
load_csv_to_bigquery("Dim_NearbyPlaces.csv", "hotel_nearby_places")
load_csv_to_bigquery("Dim_Review.csv", "hotel_reviews")
load_csv_to_bigquery("Dim_RoomType.csv", "room_types")
load_csv_to_bigquery("Fact_Booking.csv", "room_prices")
print("=== HOÀN TẤT LƯỒNG NẠP DỮ LIỆU ===")
```

BigQuery sử dụng kiến trúc lưu trữ cột (Columnar Storage), cho phép xử lý các truy vấn tổng hợp trên khối lượng dữ liệu lớn với hiệu năng cao. Các bảng dữ liệu trên BigQuery được sử dụng làm nguồn dữ liệu cho Looker Studio Dashboard, báo cáo quản trị và các phân tích chuyên sâu về xu hướng thị trường khách sạn tại Đà Nẵng.



The screenshot shows the Google BigQuery interface. On the left, there's a sidebar with a search bar and a list of resources. The main area displays a table named 'hotels' with the following columns: Row, hotel_id, hotel_name, description, stars_rating, review_count, popular_facilities, property_type, checkin_time_start, and checkin_s. The table contains 5 rows of data for different hotels in Da Nang.

Row	hotel_id	hotel_name	description	stars_rating	review_count	popular_facilities	property_type	checkin_time_start	checkin_s
1	khai-villa-private-pool-6br-walk-t...	Khái Villa Private Pool 6BR Walk...	Với hồ bơi ngoài trời, khu vườn và phòng cho thuê chung, Khái Villa Private Pool 6BR Walk to Han Market and Han River nằm ở trung tâm Đà Nẵng, cách Bãi...	0	10	Sân thượng / hiên, WiFi miễn phí, Lễ tân 24 giờ, Phòng không hút thuốc, Phòng gia đình, Hồ bơi ngoài trời, Chỗ đỗ xe miễn phí	Khách sạn	15:00	23:30
2	la-maison-des-delices	La Maison Des Délices	Nằm ở Đà Nẵng, cách Bãi biển Thanh Bình 2.5 km và Bảo tàng điêu khắc Chăm 2.6 km, La Maison Des Délices cung cấp chỗ nghỉ có Wi-Fi miễn...	0	349	Thang máy, Sân thượng / hiên, WiFi miễn phí, Lễ tân 24 giờ, Phòng không hút thuốc, Phòng gia đình, Chỗ đỗ xe miễn phí, Dịch vụ phòng	Khách sạn	14:00	23:00
3	mayana-da-nang-by-bay-luxury	Mayana Hotel DN - by BAY LUX...	Tọa lạc ở Đà Nẵng, cách trung tâm 2.3 km và Trung tâm thương mại Indochina Riverside 4 phút đi bộ, Mayana Hotel DN - by BAY LUXURY	2	2	WiFi miễn phí	Khách sạn	14:00	00:00
4	da-nang-galaxy-apartment	Kim Ngan Phat Luxury	Với Bãi biển Mỹ Khê nằm cách đó chỉ vài bước chân, Kim Ngan Phat Luxury cung cấp chỗ nghỉ, nhà hàng, khu vườn, phòng cho thuê và sân hiên.	3	47	Thang máy, Sân thượng / hiên, WiFi miễn phí, Xe đưa đón sân bay, Giáp biển, Chỗ đậu xe (trong khuôn viên), Phòng không hút thuốc, 2 nhà hàng	Khách sạn	14:00	00:00
5	pota-amp-apartment-hai-chau	POTA Hotel & Apartment	Nằm tại vị trí thuận tiện ở Đà Nẵng, POTA Hotel & Apartment cung cấp các phòng có điều hòa, phòng ch...	3	225	WiFi miễn phí, Phòng không hút thuốc, Dịch vụ phòng, Sân thượng / hiên	Khách sạn	14:00	23:30

Kết quả của giai đoạn Load:

Sau khi hoàn thành quá trình Load, toàn bộ dữ liệu khách sạn đã được lưu trữ tập trung trên PostgreSQL Cloud SQL và BigQuery Data Warehouse. PostgreSQL cung cấp nguồn dữ liệu cho các tác vụ nghiệp vụ và AI Agent, trong khi BigQuery phục vụ các nhu cầu phân tích dữ liệu, báo cáo và trực quan hóa trên nền tảng Google Cloud Platform.

3.4. Data Warehouse

Hệ thống Data Warehouse của dự án được triển khai toàn diện trên nền tảng điện toán đám mây Google Cloud Platform nhằm tối ưu hóa năng lực lưu trữ và xử lý dữ liệu thị trường khách sạn tại Đà Nẵng:

Core Data Warehouse: Sử dụng Google BigQuery làm kho dữ liệu trung tâm. Với kiến trúc Serverless và khả năng tính toán phân tán, BigQuery cho phép lưu trữ toàn bộ dữ liệu thô cào về từ các nền tảng OTA và thực thi các truy vấn phức tạp trên tập dữ liệu lớn với tốc độ tối ưu.

Data Location: Toàn bộ dữ liệu được cấu hình tại phân vùng máy chủ asia-southeast1 nhằm đảm bảo tốc độ đường truyền nhanh nhất, tối ưu độ trễ khi truy xuất dữ liệu từ Việt Nam và tuân thủ các chính sách bảo mật vùng.

Tổ chức cấu trúc Dữ liệu

Dữ liệu sau khi làm sạch được chuyển đổi từ dạng bảng phẳng sang cấu trúc sơ đồ hình sao trong phân tách rõ ràng thành hai thành phần:

1 Bảng Fact trung tâm (fact_room_prices): Lưu trữ các sự kiện biến động mang tính định lượng giá gốc, giá hiện tại, phần trăm giảm giá và tập hợp tất cả các cột khóa ngoại.

7 Bảng Dimensions: Lưu trữ các thuộc tính định tính làm bối cảnh phân tích, bao gồm: dim_hotels, dim_hotel_locations, dim_hotel_facilities, dim_hotel_nearby_places, dim_hotel_reviews, dim_room_types và dim_date.



Bảng trung tâm

fact_room_prices: Bảng Fact lõi lưu trữ toàn bộ số liệu đo lường định lượng biến động (giá phòng, giảm giá, ngày check-in/check-out) và là nơi tập trung các khóa ngoại để kết nối ra xung quanh.

Query results								Chat	Save results	Open in	
Job information		Results	Visualization	JSON	Execution details	Execution graph					
Row	booking_id	date_key	hotel_id	room_type_id	location_id	review_id	origi				
1	389-hz-homestay_phong_tieu_c...	20260625	389-hz-homestay	389-hz-homestay_phong_tieu_c...	389-hz-homestay	389-hz-homestay_rev					
2	389-hz-homestay_phong_tieu_c...	20260625	389-hz-homestay	389-hz-homestay_phong_tieu_c...	389-hz-homestay	389-hz-homestay_rev					
3	389-hz-homestay_phong_tieu_c...	20260625	389-hz-homestay	389-hz-homestay_phong_tieu_c...	389-hz-homestay	389-hz-homestay_rev					
4	389-hz-homestay_can_ho_1_ph...	20260625	389-hz-homestay	389-hz-homestay_can_ho_1_ph...	389-hz-homestay	389-hz-homestay_rev					
5	389-hz-homestay_can_ho_2_tan...	20260625	389-hz-homestay	389-hz-homestay_can_ho_2_tan...	389-hz-homestay	389-hz-homestay_rev					
6	7seven-sea_phong_superior_glu...	20260625	7seven-sea	7seven-sea_phong_superior_glu...	7seven-sea	7seven-sea_rev					
7	7seven-sea_phong_superior_glu...	20260625	7seven-sea	7seven-sea_phong_superior_glu...	7seven-sea	7seven-sea_rev					
8	7seven-sea_phong_3_nguoi_nhi...	20260625	7seven-sea	7seven-sea_phong_3_nguoi_nhi...	7seven-sea	7seven-sea_rev					
9	7seven-sea_can_ho_kieu_studio...	20260625	7seven-sea	7seven-sea_can_ho_kieu_studio...	7seven-sea	7seven-sea_rev					
10	abogo-apartment-resort-beac h-da-nang_can_ho_1_phong_n gu_1_2026-07-06	20260625	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...					
11	abogo-apartment-resort-beac h-da-nang_can_ho_1_phong_n gu_2_2026-07-06	20260625	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...					
12	abogo-apartment-resort-beac	20260625	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...					

Results per page: 50 1 – 50 of 100

Bảng chiều

dim_hotels: Bảng chiều lưu trữ thông tin thuộc tính cơ bản của khách sạn (Tên, xếp hạng sao, loại hình lưu trú, giờ check-in/out).

Query results											Chat	Save results	Open in	
Job information		Results	Visualization	JSON	Execution details	Execution graph								
Row	hotel_id	hotel_name	description	star...	property...	popular_facilities	checkin...	checkin...	check...	checko...				
1	khai-villa-private-po...	Khái Villa Private Pool 6...	Với hồ bơi ngoài trời, khu vườn và phòng chờ chung, Khái Villa Private Pool 6BR Walk to Han Market and Han River nằm ở trung tâm Đà Nẵng, cách Bãi	0	Khách sạn	Sân thượng / hiên, WIFI miễn phí, Lễ tân 24 giờ, Phòng không hút thuốc, Phòng gia đình, Hồ bơi ngoài trời, Chỗ đỗ xe miễn phí	15:00	23:30	02:00	11:00				
2	la-maison-des-delic...	La Maison Des Délices	Nằm ở Đà Nẵng, cách Bãi biển Thanh Bình 2.5 km và Bảo tàng điêu khắc Chăm 2.6 km, La Maison Des Délices cung cấp chỗ nghỉ có Wi-Fi miễn	0	Khách sạn	Thang máy, Sân thượng / hiên, WIFI miễn phí, Lễ tân 24 giờ, Phòng không hút thuốc, Phòng gia đình, Chỗ đỗ xe miễn phí, Dịch vụ phòng	14:00	23:00	10:30	11:00				
3	mayana-da-nang-by...	Mayana Hotel DN - by B...	Tọa lạc ở Đà Nẵng, cách trung tâm 2.3 km và Trung tâm thương mại Indochina Riverside 4 phút đi bộ, Mayana Hotel DN - by BAY LUXURY	2	Khách sạn	WIFI miễn phí	14:00	00:00	03:00	12:00				
4	da-nang-galaxy-apa...	Kim Ngan Phat Luxury	Với Bãi biển Mỹ Khê nằm cách đó chỉ vài bước chân, Kim	3	Khách sạn	Thang máy, Sân thượng / hiên, WIFI miễn phí, Xe đưa đón sân	14:00	00:00	05:30	12:00				

Results per page: 50 1 – 50 of 100

dim_hotel_locations: Bảng chiều lưu trữ thông tin vị trí, địa chỉ hành chính chi tiết và tọa độ kinh/vĩ độ GPS của khách sạn.

Query results

Chat

Save results

Open in

Job information

Results

Visualization

JSON

Execution details

Execution graph

Row	loc...	hotel_id	street_address	city	country	full_address	latitude	longitude
1	1	389-hz-homestay	389 Ông Ích Khiêm	Đà Nẵng	Việt Na...	389 Ông Ích Khiêm, Đà Nẵng, Vi...	16.0635697	108.2156326
2	2	7seven-sea	150 Vo Nguyen Giap, Phuoc My Ward, Son Tra Trá, Thành phố Đà Nẵng	Đà Nẵng	Việt Na...	150 Vo Nguyen Giap, Phuoc My Ward, Son Tra Trá, Thành phố Đà Nẵng, Đà Nẵng, Việt Nam	16.075448	108.244749
3	3	abogo-apartment-resort-be...	05 Trường Sa, Ngũ Hành Sơn, Đ...	Đà Nẵng	Việt Na...	05 Trường Sa, Ngũ Hành Sơn, Đà Nẵng Hyatt Regency Đà Nẵng, Đà Nẵng, Việt Nam	16.012847	108.263977
4	4	abogo-resort-villa-beach-pr...	99 Vo Nguyen Giap, Ngu Hanh S...	Đà Nẵng	Việt Na...	99 Vo Nguyen Giap, Ngu Hanh S...	16.04118047047...	108.2489996963...
5	5	airport-homestay-hai-chau1	34 Thi Sách 34/28 thi sách	Đà Nẵng	Việt Na...	34 Thi Sách 34/28 thi sách, Đà ...	16.05345436368...	108.2046135912...
6	6	alansea	Lô A6, Lê Đức Thọ, Nại Hiên Đò...	Đà Nẵng	Việt Na...	Lô A6, Lê Đức Thọ, Nại Hiên Đò...	16.100614258934	108.2320099098...
7	7	alcove-da-nang-bay-boutiqu...	10-12 Ton That Dam, Thanh Khe	Đà Nẵng	Việt Na...	10-12 Ton That Dam, Thanh Kh...	16.07224901530...	108.2014401638...
8	8	allin-da-nang-an-hai	Nguyễn Cao Luyện	Đà Nẵng	Việt Na...	Nguyễn Cao Luyện, Đà Nẵng, Vi...	16.069369768184	108.2416306373...
9	9	alysa-da-nang-da-nang	109d Dương Đình Nghệ	Đà Nẵng	Việt Na...	109d Dương Đình Nghệ, Đà Năn...	16.068595	108.238877
10	10	amber-bay-suites-da-nang	63 Dương Đình Nghe	Đà Nẵng	Việt Na...	63 Dương Đình Nghe, Đà Nẵng, ...	16.068717	108.2419368
11	11	an-duc	117 Minh Mang, Khuê My Ward...	Đà Nẵng	Việt Na...	117 Minh Mang, Khuê My	16.016671	108.255697

Results per page: 501 – 50 of 100

Results per page: 50 1 – 50 of 100

dim_hotel_facilities: Bảng chiều lưu trữ danh mục các tiện ích dịch vụ chi tiết đi kèm của từng cơ sở lưu trú.

Query results

Chat

Save results

Open in

Job information

Results

Visualization

JSON

Execution details

Execution graph

Row	facility_id	string_field_0	string_field_1
1	1	abogo-resort-villa-beach-premium	2 hồ bơi
2	2	anna-danang-amazing-beach	2 hồ bơi
3	3	astana-villa-non-nuoc-beach	2 hồ bơi
4	4	bella-ciao-homestay-da-nang	2 hồ bơi
5	5	blue-sky-amp-villas-beach-resort	2 hồ bơi
6	6	cani-beach-house	2 hồ bơi
7	7	cordial	2 hồ bơi
8	8	diamond-beach-villa-da-nang	2 hồ bơi
9	9	dlig-da-nang	2 hồ bơi
10	10	flower-da-nang	2 hồ bơi
11	11	four-points-by-sheraton-danang	2 hồ bơi
12	12	furama-resort-danang	2 hồ bơi
13	13	furama-villa-in-da-nang	2 hồ bơi
14	14	goldcoast-da-nang	2 hồ bơi
15	15	intercontinental-danang-sun-peninsula-resort	2 hồ bơi

Results per page:

50

1 – 50 of 100

Results per page: 50 1 – 50 of 100

dim_hotel_nearby_places: Bảng chiều lưu trữ thông tin các điểm tham quan lân cận (POI) cùng khoảng cách quy đổi và thứ hạng khoảng cách từ khách sạn đến điểm đó.

Query results

Chat

Save results

Open in

Job information

Results

Visualization

JSON

Execution details

Execution graph

Row	place...	hotelLid	place_name	place_type	dist...	dist...	dist...	dist...
1	1	awaken-da-nang	Nhà hàng Nhà Hàng Phương Anh	restaurant	0.0	m	0	1
2	2	happy-day	Nhà hàng Cô Lưu Café	restaurant	0.0	m	0	1
3	3	happy-day	Nhà hàng Cô Ba Phở Bò	restaurant	0.0	m	0	2
4	4	mayana-da-nang-by-bay-luxury	Cafe/quán bar Cong Caphe	restaurant	0.0	m	0	1
5	5	monarque	Nhà hàng Nhà Hàng Nem	restaurant	0.0	m	0	1
6	6	ruby-danang	Nhà hàng The Billa Bong	restaurant	0.0	m	0	1
7	7	silana-amp-apartment-ngu-han...	Nhà hàng Quán Bắc Hà	restaurant	0.0	m	0	1
8	8	sujet-residence-service-da-nang	Nhà hàng Pho 29	restaurant	0.0	m	0	1
9	9	taiyo-amp-apartment	Nhà hàng Nhà Hàng Ấn Độ Mah...	restaurant	0.0	m	0	1
10	10	airport-homestay-hai-chau1	Cafe/quán bar Airport Homestay	restaurant	1.0	m	1	1
11	11	brilliant	Nhà hàng Cô Lưu Café	restaurant	1.0	m	1	1
12	12	brilliant	Nhà hàng Cô Ba Phở Bò	restaurant	1.0	m	1	2
13	13	dana-home-department	Nhà hàng Quán Com Gà Phở Hội	restaurant	1.0	m	1	1
14	14	emerald-and-apartments	Cafe/quán bar Lagom Hostel A...	restaurant	1.0	m	1	1
15	15	green-home-lien-chieu	Nhà hàng Chuyên Bún Chả Nem...	restaurant	1.0	m	1	1

Results per page: 501 – 50 of 100

|<

<

>

|>

dim_hotel_reviews: Bảng chiều lưu trữ chi tiết hệ thống điểm số đánh giá danh tiếng theo từng khía cạnh trải nghiệm của du khách.

Query results

Chat

Save results

Open in

Job information

Results

Visualization

JSON

Execution details

Execution graph

Row	review_id	hotel_id	sta...	facilities...	cleani...	comfor...	value...	locati...	free_wi...	averag...
1	an-duc_rev	an-duc	5.1	4.5	4.1	4.1	4.6	4.1	2.5	5.7
2	sen-vang-da-nang_rev	sen-vang-da-nang	4.9	4.5	4.5	4.7	4.7	5.3	6.7	3.7
3	oyo-266-golden-gate_rev	oyo-266-golden-gate	5.9	5.0	5.4	5.5	6.1	7.4	5.9	4.5
4	vinh-trung-plaza-apartment_rev	vinh-trung-plaza-apartment	5.8	4.6	5.4	5.4	5.4	6.3	0.0	4.0
5	danabeach-motel-thanh-khe_rev	danabeach-motel-thanh-khe	6.0	6.1	5.8	5.7	6.5	7.0	0.0	4.1
6	olalani-resort-amp-condotel_rev	olalani-resort-amp-condotel	7.1	6.6	6.9	7.1	6.5	7.4	5.0	6.7
7	motel-mot_rev	motel-mot	6.7	7.5	7.5	8.3	8.3	8.3	0.0	7.0
8	allin-da-nang-an-hai_rev	allin-da-nang-an-hai	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
9	b-luxury-building_rev	b-luxury-building	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
10	chau-anh-dn-by-bay-luxury_rev	chau-anh-dn-by-bay-luxury	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
11	comic-2-homestay_rev	comic-2-homestay	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
12	cozy-apartment-near-my-khe-be...	cozy-apartment-near-my-khe-be...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
13	didau-homestay_rev	didau-homestay	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
14	emlyhome-hanriver_rev	emlyhome-hanriver	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
15	hh-apartment-ii_rev	hh-apartment-ii	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Results per page:

50

1 – 50 of 100

<

<

>

>

dim_room_types: Bảng chiều lưu trữ đặc tả cấu trúc hạng phòng, loại giường và sức chứa tối đa của phòng.

Query results [Chat](#) [Save results](#) [Open in](#)

Job information	Results	Visualization	JSON	Execution details	Execution graph
Row	room_type_id	hotel_id	room_type_name	bed_types	max_guests
1	389-hz-homestay_phong_tieu_c...	389-hz-homestay	Phòng Tiêu Chuẩn Giường Đôi	Không xác định	2
2	389-hz-homestay_phong_tieu_c...	389-hz-homestay	Phòng Tiêu Chuẩn Giường Đôi	Không xác định	2
3	389-hz-homestay_phong_tieu_c...	389-hz-homestay	Phòng Tiêu Chuẩn 3 Người	Không xác định	2
4	389-hz-homestay_can_ho_1_ph...	389-hz-homestay	Căn Hộ 1 Phòng Ngủ Có Ban Cồ...	Không xác định	2
5	389-hz-homestay_can_ho_2_tan...	389-hz-homestay	Căn Hộ 2 Tầng	Không xác định	2
6	7seven-sea_phong_superior_giu...	7seven-sea	Phòng Superior Giường Đôi	Không xác định	2
7	7seven-sea_phong_superior_giu...	7seven-sea	Phòng Superior Giường Đôi	Không xác định	2
8	7seven-sea_phong_3_nguoi_nhi...	7seven-sea	Phòng 3 Người Nhìn Ra Biển	Không xác định	2
9	7seven-sea_can_ho_kieu_studio...	7seven-sea	Căn hộ kiểu Studio Nhìn ra Biển	Không xác định	2
10	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2
11	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2
12	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2
13	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2
14	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2
15	abogo-apartment-resort-beach...	abogo-apartment-resort-beach...	Căn Hộ 1 Phòng Ngủ	Không xác định	2

Results per page: 50 1 – 50 of 100

dim_date: Bảng chiều trực thời gian giúp phân tích xu hướng biến động giá theo thứ, ngày cuối tuần hoặc mùa du lịch cao điểm của Đà Nẵng.

Query results

Chat

Save results

Open in

Job information

Results

Visualization

JSON

Execution details

Execution graph

Row	date_key	full_date	day_of_week	is_weekend	month_name	quarter	is_tourist_s...
1	20260625	2026-06-25	Thursday	false	June	2	true

Results per page: 50

1 – 1 of 1

IV. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết luận

Trong phạm vi nghiên cứu của đề tài, nhóm đã đạt được những kết quả đáng kể trong việc ứng dụng Data Engineering và các công nghệ đám mây vào bài toán xây dựng hệ thống dữ liệu tự động phục vụ gợi ý du lịch và tối ưu hóa trải nghiệm khách hàng tại Đà Nẵng trên nền tảng Google Cloud Platform.

Trước hết, đề tài đã xây dựng được một quy trình thu thập và xử lý dữ liệu tương đối hoàn chỉnh, tự động hóa việc khai thác thông tin khách sạn, giá phòng và đánh giá từ các nền tảng đặt phòng trực tuyến như Booking.com và Agoda. Quy trình ETL được thiết kế bài bản, giúp cải thiện chất lượng dữ liệu đầu vào thông qua việc xử lý giá trị thiếu, chuẩn hóa định dạng và tổ chức lưu trữ có cấu trúc, từ đó khắc phục tình trạng dữ liệu phân tán và thiếu đồng nhất.

Bên cạnh đó, thông qua việc xây dựng kho dữ liệu trên BigQuery và cơ sở dữ liệu tác nghiệp trên PostgreSQL, đề tài đã tạo ra một nền tảng dữ liệu vững chắc, có khả năng phục vụ phân tích đa chiều về thị trường lưu trú tại Đà Nẵng. Điều này góp phần khai thác hiệu quả nguồn dữ liệu thực tế để hỗ trợ ra quyết định cho cả người dùng lẫn các đơn vị kinh doanh du lịch.

Quan trọng hơn, kết quả đạt được đã chứng minh rằng với sự hỗ trợ của các dịch vụ đám mây hiện đại, hoàn toàn có thể xây dựng một hệ thống dữ liệu tự động hóa, tiết kiệm chi phí và có khả năng mở rộng mà không đòi hỏi hạ tầng vật lý phức tạp. Thông qua quá trình thực hiện, nhóm không chỉ củng cố được các kiến thức lý thuyết về pipeline dữ liệu, mô hình kho dữ liệu mà còn tích lũy được kinh nghiệm thực tiễn trong việc triển khai một hệ thống hoàn chỉnh từ khâu thiết kế kiến trúc đến vận hành trên môi trường đám mây.

Nhìn chung, đề tài đã hoàn thành các mục tiêu đề ra và đặt nền móng vững chắc cho các bước phát triển tiếp theo, hướng đến một hệ thống tư vấn du lịch thông minh và toàn diện bao gồm tầng Multi - Agent AI và Dashboard trực quan hóa trong bối cảnh chuyển đổi số ngành du lịch ngày càng mạnh mẽ.

2. Hạn chế của đề tài

Nguồn dữ liệu còn hạn chế: Mới chỉ thu thập từ Booking.com và Agoda, chưa tích hợp được các nền tảng khác như Google Maps, TripAdvisor hay các nền tảng

nội địa như Traveloka, Vntrip. Điều này khiến bức tranh thị trường chưa thực sự toàn diện.

Chưa xử lý dữ liệu thời gian thực: Pipeline hiện tại hoạt động theo mô hình batch định kỳ, chưa phản ánh được sự biến động giá phòng tức thời, đặc biệt trong các dịp lễ hay sự kiện lớn tại Đà Nẵng.

Rủi ro từ thay đổi cấu trúc trang web: Khi Booking.com hoặc Agoda thay đổi giao diện HTML, bộ scraper có thể bị lỗi và cần được cập nhật thủ công, ảnh hưởng đến tính liên tục của pipeline.

Phạm vi địa lý còn giới hạn: Hệ thống chỉ tập trung vào thành phố Đà Nẵng, chưa có khả năng mở rộng tự động sang các điểm du lịch khác.

3. Hướng phát triển trong tương lai

Mở rộng và làm giàu dữ liệu: Tích hợp thêm dữ liệu từ Google Maps, TripAdvisor và các nền tảng đặt phòng nội địa. Đồng thời mở rộng phạm vi địa lý sang các tỉnh thành du lịch lớn khác tại Việt Nam như Hội An, Nha Trang, Phú Quốc.

Chuyển sang xử lý streaming: Tích hợp Google Pub/Sub và Dataflow để cập nhật dữ liệu giá phòng gần thời gian thực, phản ánh kịp thời các biến động thị trường.

Phân tích cảm xúc từ đánh giá: Áp dụng các mô hình NLP để khai thác nội dung văn bản bài đánh giá của khách hàng, từ đó xây dựng chỉ số chất lượng dịch vụ chi tiết và khách quan hơn.

Cá nhân hóa gợi ý: Phát triển hệ thống gợi ý dựa trên lịch sử tìm kiếm và sở thích của từng người dùng bằng các thuật toán Collaborative Filtering hoặc Content-Based Filtering, thay vì chỉ lọc theo tiêu chí nhập tay.

Hoàn thiện tầng AI và trực quan hóa: Triển khai đầy đủ hệ thống Multi - Agent AI trên Vertex AI và Dashboard phân tích trên Looker Studio, đưa toàn bộ hệ thống vào khai thác thực tế một cách hoàn chỉnh.

TÀI LIỆU THAM KHẢO

- [1] Evytechno. (n.d.). *MATE – Modern data architecture*. Evytechno Blog. <https://www.evytechno.com/blog/mate>
- [2] Meloccaro, S. (n.d.). *Data warehouse schemas explained: Star, snowflake & galaxy*. Medium. <https://medium.com/@StefanoMeloccaro/data-warehouse-schemas-explained-star-snowflake-galaxy-d2c508d9ac5f>
- [3] Monte Carlo. (n.d.). *Data warehouse schemas: A complete guide*. Monte Carlo Blog. <https://montecarlo.ai/blog-data-warehouse-schemas/>
- [4] Google Cloud. (n.d.). *Google Cloud products*. Google LLC. <https://cloud.google.com/products?hl=vi>
- [5] Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65–74. <https://doi.org/10.1145/565117.565137>
- [6] Reis, J., & Housley, M. (2022). *Fundamentals of data engineering: Plan and build robust data systems*. O'Reilly Media. <https://www.oreilly.com/library/view/fundamentals-of-data/9781098108298/>